


Analyse NLP des rapports d'incidents de sécurité aérienne

Extraction des causes récurrentes, classification des incidents
et détection de signaux faibles sur la base **NASA ASRS**

Projection UMAP des rapports (couleur = catégorie)



Projection sémantique des 125 763 rapports — coloration par catégorie d'incident

Dataset	NASA ASRS — 125 763 rapports (2002–2025)
Équipe	3 étudiants 3–4 semaines
Livrables	Pipeline NLP · Dashboards (Streamlit & React) · Rapport
Dépôt	https://github.com/devMehdi485/asrs-ml

Table des matières

1 Contexte et problématique 2

2 Objectifs 2

3 Données 2

4 Méthodologie 2

4.1 Prétraitement NLP 2

4.2 Vectorisation 2

4.3 Clustering thématique 3

4.4 Interprétation des thèmes 3

4.5 Classification supervisée 3

4.6 Signaux faibles et analyse temporelle 3

5 Résultats 3

5.1 Cartographie thématique 3

5.2 Cohérence des clusters 3

5.3 Interprétabilité — modèle LDA & word2vec 4

5.4 Classification supervisée 4

5.5 Évolution temporelle 4

5.6 Causes récurrentes 4

6 Dashboards 5

7 Adéquation aux critères d'évaluation 5

8 Limites et perspectives 6

9 Conclusion 6

1 Contexte et problématique

Chaque année, pilotes, contrôleurs et techniciens soumettent volontairement et de manière confidentielle des milliers de rapports d'incidents à la NASA via l'*Aviation Safety Reporting System* (ASRS). Chaque rapport contient un **récit en texte libre** décrivant l'événement, accompagné de métadonnées codées par des experts. Cette base constitue une mine d'informations sur les risques systémiques de l'aviation, mais elle reste **largement inexploitée** faute d'outils capables d'analyser automatiquement des dizaines de milliers de narratives.

Problématique. Comment faire parler automatiquement ces récits pour (i) extraire les *causes récurrentes* d'incidents, (ii) *classifier* les types d'incidents et (iii) détecter des *signaux faibles* précurseurs d'accidents ?

2 Objectifs

- Construire un **pipeline NLP complet** : prétraitement → vectorisation → clustering.
- Faire émerger des **thèmes d'incidents** cohérents et interprétables (non supervisé).
- **Classifier** le type d'anomalie à partir du texte (supervisé).
- Repérer des **signaux faibles** (rapports atypiques) et analyser l'**évolution temporelle**.
- Livrer un **dashboard interactif** de qualité professionnelle.

3 Données

Source. NASA ASRS — asrs.arc.nasa.gov/search/database.html (accès libre). L'outil officiel limite chaque export à 10 000 rapports ; nous avons travaillé sur un export complet de **125 763 rapports** (2002–2025) afin d'obtenir une couverture statistique et temporelle robuste.

Variables clés (taux de remplissage mesuré sur le corpus) :

- *Narratives* Reporter 1 & 2 et *Synopsis* (texte libre) — 100 %.
- Type d'**anomalie** (cible supervisée) — 99,7 % ; **phase de vol** — 95,9 % ; **type d'aéronef** — 98,9 % ; **date** — 100 %.
- Conditions météo, détecteur, problème principal, facteurs contributifs — partiellement remplis.

Particularité technique. Les exports ASRS comportent une *double ligne d'en-tête* (catégorie + sous-champ), gérée automatiquement par le module de chargement (aplatissement et repérage des colonnes par mots-clés).

4 Méthodologie

4.1 Prétraitement NLP

Nettoyage des artefacts de désidentification (ZZZ, tokens masqués), mise en minuscules, tokenisation, suppression des *stopwords* (anglais + liste métier aéronautique), puis **lemmatisation** (NLTK). Deux versions du texte sont produites : une version « naturelle » (pour les embeddings de phrases) et une version « sac-de-mots » lemmatisée (pour TF-IDF et LDA).

4.2 Vectorisation

- **TF-IDF** (uni + bigrammes) : représentation creuse et interprétable, base de la classification et de la labellisation des clusters.
- **Word embeddings (word2vec)** : un modèle *gensim* Word2Vec entraîné sur le corpus capture la sémantique lexicale du domaine (cf. tableau 2).

- **Embeddings de phrases** (**sentence-transformers**, **all-MiniLM-L6-v2**) : représentation contextuelle dense, utilisée pour le clustering. Ce choix constitue une *amélioration* par rapport à word2vec/GloVe (le brief), les embeddings de phrases capturant le sens global d'un récit plutôt que des mots isolés.

4.3 Clustering thématique

Les embeddings sont réduits par **UMAP** puis regroupés. Deux algorithmes sont comparés sur les *mêmes* données (tableau 1) : **K-Means** (granularité fixée pour l'interprétabilité) et **HDBSCAN** (densité, gère le bruit). Une règle de décision explicite sélectionne le modèle final ; un garde-fou rejette tout HDBSCAN dégénéré (<6 clusters). La modélisation **LDA** (Latent Dirichlet Allocation) complète l'analyse par une vue probabiliste des thèmes, évaluée par la **cohérence** c_v .

4.4 Interprétation des thèmes

Pour chaque cluster : extraction des termes saillants par **c-TF-IDF**, **labellisation** (nom métier + description rédigée), **synthèse** et narratives représentatives. Les 81 thèmes ont été regroupés en **11 catégories** métier (figure 1).

4.5 Classification supervisée

Cible : l'anomalie principale (top-8 classes les plus fréquentes). Modèles : **Régression logistique** et **SVM linéaire** sur TF-IDF (tableau 3).

4.6 Signaux faibles et analyse temporelle

Détection d'**Isolation Forest** sur les embeddings réduits (complétée par le bruit HDBSCAN) pour isoler les rapports atypiques. L'analyse temporelle agrège les volumes mensuels, détecte les pics (z-score) et suit la part de chaque thème dans le temps.

5 Résultats

5.1 Cartographie thématique

Le clustering produit **81 thèmes** fins et interprétables, regroupés en 11 catégories. L'équipement et les systèmes dominant (43,8 % du corpus), suivis des incidents au sol/piste (13,3 %) et des écarts de trajectoire/altitude (7,8 %).

5.2 Cohérence des clusters

TABLE 1 — Comparaison K-Means vs HDBSCAN (mêmes données réduites UMAP).

Modèle	Clusters	Silhouette	Davies-B.	Calinski-H.	Bruit	Pureté
K-Means	15	0,382	0,945	290 094	0 %	0,133
HDBSCAN	81	0,590	0,575	69 804	32 %	0,165

Modèle retenu : HDBSCAN — meilleure silhouette (0,590 vs 0,382) et Davies-Bouldin plus faible, avec un taux de bruit (32 %) réutilisé pour la détection de signaux faibles. La faible valeur d'ARI/pureté vis-à-vis du champ *Anomaly* est attendue : les thèmes sont sémantiques (vocabulaire des récits) et plus fins que les catégories d'anomalies codées.




FIGURE 1 — Répartition des incidents par catégorie métier.

5.3 Interprétabilité — modèle LDA & word2vec

La cohérence moyenne du modèle LDA atteint $c_v = 0,57$, signe de thèmes lexicalement cohérents. Le modèle word2vec entraîné sur le corpus capture une sémantique aéronautique fine :

TABLE 2 — word2vec — mots les plus proches (similarité cosinus).

Mot	Voisins les plus proches
runway	rwy (0,84), taxiway (0,65), intersecting (0,59), midfield (0,59)
engine	eng (0,69), feathered (0,57), magneto (0,54), crossbleed (0,54)
fuel	gas (0,69), gallon (0,60), fueled (0,60), gph (0,59)
weather	thunderstorm (0,76), storm (0,74), bkn (0,68), forecast (0,66)
altitude	alt (0,70), descended (0,67), descend (0,65), level (0,64)
gear	flap (0,62), slat (0,59), wheel (0,55), strut (0,52)

5.4 Classification supervisée

TABLE 3 — Classification du type d’incident (top-8 anomalies, TF-IDF).

Modèle	F1 macro	F1 pondéré
Régression logistique	0,518	0,606
SVM linéaire	0,517	0,615

Les meilleures classes (*ATC Issue* F1 = 0,76 ; *NMAC* 0,69 ; *Aircraft Equipment Critical* 0,67) sont bien séparées ; les classes rares et les anomalies multi-étiquettes restent plus difficiles.

5.5 Évolution temporelle

L’analyse des tendances révèle des thèmes en **hausse récente** — incursions au sol, événements de fumée/odeur, drones, marchandises dangereuses — candidats prioritaires pour un programme de sécurité.

5.6 Causes récurrentes




FIGURE 2 — Principaux thèmes d’incidents (effectifs).

TABLE 4 — Principales causes récurrentes (top 10).

Thème	Rapports	%	Tendance
Pannes avioniques & systèmes (jets régio- naux)	22 258	26,2	baisse
Incursions & erreurs au sol (taxi/piste)	8 458	10,0	hausse
Fumée, odeurs & émanations en cabine	3 393	4,0	hausse
Conflits de trafic en circuit d’aérodrome	2 657	3,1	hausse
Turbulence de sillage	2 459	2,9	stable
Maintenance & inspections	2 108	2,5	stable
Chargement, masse & marchandises dan- gereuses	1 959	2,3	hausse
Proximité du terrain à l’approche (CFIT)	1 906	2,2	stable
Coordination ATC & gestion des secteurs	1 858	2,2	stable
Problèmes de train d’atterrissage	1 805	2,1	stable

6 Dashboards

Deux tableaux de bord ont été développés :

- **Streamlit** (Python) — rapide à lancer, lit directement les artefacts.
- **AeroInsight AI** (React + TypeScript + Vite + Tailwind) — version web « pro » reproduisant la maquette, alimentée par un export JSON statique. Six pages : *Dashboard*, *Cluster Explorer* (carte sémantique + filtres par catégorie), *Thematic Analysis* (cartes de thèmes, LDA/pyLDAvis), *Temporal Map*, *Weak Signals*, *Executive Intelligence* (rapport auto-généré). Chaque thème y est présenté avec un **nom métier lisible**, une description, des **nuages de mots** et sa tendance temporelle.

7 Adéquation aux critères d’évaluation




FIGURE 3 — Nuages de mots (c-TF-IDF) des quatre principaux thèmes.




FIGURE 4 — Volume mensuel de rapports (2002–2025).

8 Limites et perspectives

Limites. Texte désidentifié (perte d'information), déséquilibre des classes d'anomalies, biais de déclaration volontaire, et un méga-cluster d'équipement au vocabulaire technique hétérogène.

Perspectives. Embeddings de domaine aéronautique (fine-tuning), classification multi-étiquettes, modélisation de séquences temporelles, et BERTopic de bout en bout.

9 Conclusion

Le projet livre un pipeline NLP complet, validé sur **125 763 rapports** réels, produisant **81 thèmes interprétables** regroupés en 11 catégories, une classification supervisée opérationnelle, une détection de signaux faibles et deux dashboards interactifs. L'ensemble transforme une masse de récits bruts en une **intelligence de sécurité** exploitable et lisible.

Données : NASA Aviation Safety Reporting System (<https://asrs.arc.nasa.gov/>). Code et dashboards : <https://github.com/devMehdi485/asrs-ml>.




FIGURE 5 — Heatmap : type d'anomalie × année.

Critère	Mise en œuvre
Cohérence des clusters	Comparaison K-Means/HDBSCAN (silhouette, Davies-Bouldin, Calinski-Harabasz), règle de décision justifiée, analyse qualitative.
Interprétabilité thé-matique	c-TF-IDF, labels métier + 11 catégories, LDA ($c_v = 0,57$) + pyLDA-vis, word2vec, tableau des causes.
Dimension temporelle	Volume mensuel, détection de pics, heatmap, topics-over-time.
Signaux faibles	Isolation Forest + bruit HDBSCAN.
Classification	Régression logistique & SVM (F1 pondéré jusqu'à 0,615).
Qualité du dashboard	Deux dashboards, dont une app React 6 pages, nuages de mots par cluster et carte temporelle.