

PROJET MACHINE LEARNING


Analyse automatique des rapports d'incidents NASA ASRS

Clustering thématique, classification des anomalies, signaux faibles
et tableau de bord d'aide à la décision

Rapport final académique

TIDJANI Mehdi
FEUDJEU II LA GRACE
OUEDRAOGO Martin

Projection UMAP des rapports (couleur = catégorie)



Projection sémantique des 125 763 rapports, colorée par catégorie d'incident

Données	NASA ASRS – 125 763 rapports
Source Kaggle	NASA ASRS Full Dataset 2005–2025
Période	juin 2002 – décembre 2025
Méthodes	TF-IDF, embeddings, UMAP, HDBSCAN, LDA, SVM
Livrables	notebook, pipeline Python, dashboard Streamlit, dashboard React, rapport PDF
Dépôt	https://github.com/devMehdi485/asrs-ml

Table des matières

1	Contexte	2
2	Problématique	2
3	Objectifs	2
4	Méthodologie	2
4.1	Données	2
4.2	Prétraitement	2
4.3	Vectorisation	3
4.4	Clustering thématique	3
4.5	Classification	4
5	Résultats	4
5.1	Cohérence des clusters	4
5.2	Interprétation des thèmes	4
5.3	Performance de la classification	5
5.4	Signaux faibles détectés	6
6	Tableau de bord	6
7	README – lancement du dashboard	7
8	Implications et recommandations	7
9	Conclusion	8

1 Contexte

La base NASA ASRS (*Aviation Safety Reporting System*) regroupe des rapports d'incidents aériens déclarés volontairement par les pilotes, contrôleurs et autres acteurs opérationnels. Chaque rapport contient un récit en texte libre décrivant le contexte, le déroulement de l'incident et les facteurs contributifs. Le projet exploite un export de **125 763 rapports** couvrant la période de juin 2002 à décembre 2025.

Le jeu de données utilisé est le dataset Kaggle *NASA ASRS Full Dataset 2005–2025*, disponible sur Kaggle.

2 Problématique

Le volume du corpus rend impossible toute lecture manuelle exhaustive, et l'information utile est enfouie dans un texte non structuré et hétérogène. La problématique est donc : **comment exploiter automatiquement les récits ASRS pour identifier les causes récurrentes, classer les anomalies et détecter les risques émergents**, au service de la sécurité aérienne ?

3 Objectifs

1. identifier automatiquement les thèmes d'incidents récurrents ;
2. classer les catégories d'anomalies à partir du texte ;
3. détecter les signaux faibles et les risques émergents ;
4. restituer les résultats dans un tableau de bord interactif.

4 Méthodologie

La chaîne de traitement enchaîne cinq étapes. Chacune est décrite par son application concrète au corpus ASRS et par le résultat obtenu, plutôt que par la théorie des algorithmes.

4.1 Données

Le pipeline charge l'export CSV, repère automatiquement les colonnes utiles (le format ASRS comporte une double ligne d'en-tête) et fusionne les champs textuels (*narrative* Reporter 1 & 2, synopsis) en un texte d'analyse par rapport. Les métadonnées (date, phase de vol, type d'anomalie) sont conservées pour interpréter les résultats.

Le corpus obtenu contient 125 763 textes ; les champs textuels sont remplis à 100 % et le type d'anomalie à 99,7 %. Les phases de vol les plus représentées sont *Cruise* (20 738 rapports), *Parked* (15 493), *Initial Approach* (12 880), *Taxi* (12 294) et *Climb* (11 132).

4.2 Prétraitement

Les textes sont nettoyés pour retirer le bruit propre au format ASRS : marqueurs d'anonymisation (ZZZ, XXX), casse, ponctuation, mots très fréquents et termes métier omniprésents (« aircraft », « flight »), puis lemmatisation des variantes.

Sans ce nettoyage, les marqueurs ZZZ — présents dans presque tous les rapports — domineraient les statistiques de mots. Après nettoyage, les termes extraits par thème deviennent réellement

discriminants : le thème des défaillances hydrauliques ressort avec **hydraulic**, **pump**, **fluid** et non avec du vocabulaire générique.

4.3 Vectorisation

Deux représentations sont produites : une matrice **TF-IDF** (mots et bigrammes) pour la classification et l'extraction de mots-clés, et des **embeddings** de phrases (all-MiniLM-L6-v2) qui encodent le sens global d'un récit pour le regroupement. Un modèle Word2Vec entraîné sur le corpus a servi à contrôler la cohérence du vocabulaire.

Le contrôle Word2Vec confirme que la sémantique aéronautique est bien captée : **runway** est le plus proche de **rw**y (0,84) et de **taxiway** (0,65) ; **weather** de **thunderstorm** (0,76). Les embeddings permettent de rapprocher deux récits décrivant le même événement avec des mots différents — situation fréquente dans des rapports rédigés librement — ce qui se traduit par un regroupement nettement plus cohérent (silhouette de 0,590, § 5.1).

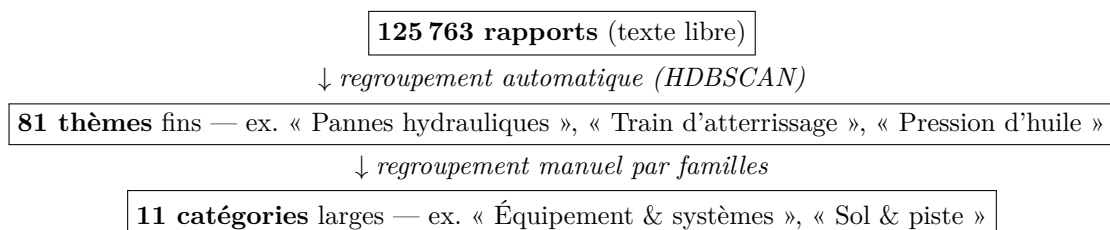
Table 1 – Word2Vec — plus proches voisins (similarité cosinus) appris sur le corpus.

Terme	Plus proches voisins
runway	rw y (0,84), taxiway (0,65), intersecting (0,59)
engine	eng (0,69), feathered (0,57), magneto (0,54)
weather	thunderstorm (0,76), storm (0,74), bkn (0,68)
altitude	alt (0,70), descended (0,67), descend (0,65)

4.4 Clustering thématique

Les embeddings sont réduits par UMAP, puis regroupés. Deux algorithmes ont été comparés sur les mêmes données : K-Means et HDBSCAN. HDBSCAN a été retenu car il découvre lui-même le nombre de groupes, gère des groupes de tailles très inégales et isole les rapports atypiques (« bruit »), réutilisés ensuite pour la détection de signaux faibles.

Le regroupement produit une structure à trois niveaux :



Nommage des thèmes (labellisation). Les noms des 81 thèmes ont été déterminés de façon semi-automatique. Pour chaque thème, les termes *distinctifs* sont extraits automatiquement par c-TF-IDF (une variante du TF-IDF appliquée au thème entier, qui retient les mots fréquents dans ce thème mais rares ailleurs) ; ils sont croisés avec l'anomalie dominante et trois récits représentatifs. À partir de ces éléments, un libellé métier lisible est rédigé et consigné dans un fichier versionné. Le clustering et l'extraction des mots-clés sont donc entièrement automatiques ; seule la mise en mots du nom relève d'une validation humaine, et n'influence aucun résultat quantitatif.

Le thème dont les termes c-TF-IDF sont **hydraulic · pump · fluid · system**, d'anomalie dominante *Aircraft Equipment Problem Critical*, est nommé « **Pannes hydrauliques** » et rattaché à la catégorie « Équipement & systèmes ».

4.5 Classification

Un modèle supervisé prédit la catégorie d'anomalie d'un rapport à partir de son texte complet (et non de mots isolés). Deux modèles linéaires ont été entraînés sur la matrice TF-IDF — régression logistique et SVM linéaire — restreints aux huit catégories d'anomalies les plus fréquentes. Le choix de modèles linéaires permet de garder une décision auditable (les mots déterminants sont lisibles), critère important en contexte de sécurité.

Sur un rapport décrivant un franchissement de piste sans autorisation, le modèle prédit la catégorie *Conflit / incursion* avec une probabilité élevée, en s'appuyant sur des termes comme **runway**, **hold short** et **clearance**.

5 Résultats

5.1 Cohérence des clusters

La comparaison des deux algorithmes (tableau 2) établit la supériorité d'HDBSCAN : silhouette de 0,590 (contre 0,382) et indice de Davies-Bouldin de 0,575 (contre 0,945), traduisant des groupes plus compacts et mieux séparés. HDBSCAN forme 81 thèmes et classe 32,5 % des rapports comme atypiques (« bruit »), réutilisés en § 5.4. La faible concordance avec les catégories officielles (pureté de 0,165) n'est pas un défaut : elle reflète la granularité plus fine des thèmes issus du texte par rapport à la nomenclature des analystes.




Figure 1 — Projection UMAP des rapports ASRS : chaque point représente un rapport et la couleur indique sa catégorie thématique.


5.2 Interprétation des thèmes

Les 81 thèmes se répartissent en 11 catégories (figure 2). La catégorie **Équipement & systèmes** domine avec **43,8 %** des rapports, devant **Sol & piste** (13,3 %) et **Trajectoire & altitude**

Table 2 – Indices internes de qualité du regroupement.

Algorithme	Groupes	Silhouette	Davies-Bouldin	Bruit	Pureté
K-Means	15	0,382	0,945	0 %	0,133
HDBSCAN	81	0,590	0,575	32 %	0,165

(7,8 %). Cette prédominance s’interprète comme une forte propension des équipages à signaler les dysfonctionnements techniques.

**Figure 2** – Répartition des rapports par catégorie (81 thèmes regroupés en 11 familles).

Concrètement, les thèmes les plus volumineux (figure 3) sont : pannes avioniques et systèmes (22 258 rapports), incursions et erreurs au sol (8 458), fumées et odeurs en cabine (3 392), conflits de trafic en circuit d’aérodrome (2 656), turbulence de sillage (2 459), maintenance et inspections (2 108), chargement et marchandises dangereuses (1 959), proximité du terrain à l’approche (1 907), coordination ATC (1 858) et problèmes de train d’atterrissage (1 804).

Pour interpréter rapidement un thème, le tableau de bord en affiche le **nuage de mots** : les termes les plus distinctifs y sont dimensionnés selon leur importance, ce qui permet d’identifier le contenu d’un thème d’un coup d’œil sans lire les rapports (figure 4).

5.3 Performance de la classification

Le SVM linéaire atteint un **F1 pondéré de 0,615** (tableau 3). L’écart avec le F1 macro (0,517) traduit l’effet du déséquilibre des classes : les catégories au vocabulaire spécifique sont bien reconnues — *ATC Issue* (F1 = 0,76), *Conflict NMAC* (0,69), *Aircraft Equipment Problem Critical* (0,67) — tandis que les classes rares abaissent la moyenne.

Table 3 – Classification de la catégorie d’anomalie (8 classes, entrées TF-IDF).

Modèle	F1 macro	F1 pondéré
Régression logistique	0,518	0,606
SVM linéaire	0,517	0,615

Le détail par classe (tableau 4) montre que les catégories au vocabulaire spécifique sont bien reconnues, tandis que les classes rares restent difficiles.




Figure 3 – Douze thèmes les plus volumineux.

Table 4 – Performance par classe (régression logistique).

Catégorie d'anomalie	Précision	Rappel	F1
ATC Issue All Types	0,86	0,68	0,76
Conflict NMAC	0,65	0,73	0,69
Aircraft Equipment Problem Critical	0,80	0,58	0,67
Conflict Ground Conflict	0,52	0,64	0,58
Aircraft Equipment Problem Less Severe	0,53	0,44	0,48
Conflict Airborne Conflict	0,24	0,28	0,26

5.4 Signaux faibles détectés

La détection d'anomalies (Isolation Forest sur les représentations, complétée par le bruit HDBSCAN) isole les rapports les plus atypiques. Leur examen fait ressortir des thématiques rares mais à fort enjeu, quasi absentes en début de période : **rencontres avec des drones, brouillage du signal GPS** et **batteries au lithium**. Un rapport représentatif illustre la catégorie « drones » :

« Approach control advised there was unauthorized drone use in the area. . . I observed a drone pass just left of the aircraft, approximately 20 feet from our left wing. »

L'évolution temporelle (figure 5) confirme par ailleurs la **progression récente** de trois thèmes : incursions au sol, fumées en cabine et marchandises dangereuses.

6 Tableau de bord

Les résultats sont restitués dans deux tableaux de bord interactifs : une version **Streamlit** (Python) et une application web **React** (« AeroInsight AI »).

La version Streamlit a été simplifiée pour l'usage de présentation. Elle contient uniquement deux vues :

- le **nuage de mots par cluster**, qui permet de comprendre rapidement le contenu d'un thème ;
- la **carte temporelle des incidents**, qui montre l'évolution des volumes et des anomalies dans le temps.




Figure 4 – Nuages de mots des quatre principaux thèmes : les termes distinctifs (taille proportionnelle à l'importance) résument le contenu de chaque thème.

La version React (« AeroInsight AI ») sert de tableau de bord complet, organisé en plusieurs pages : une vue d'ensemble, un **explorateur de clusters** (carte sémantique colorée par catégorie avec étiquettes et filtres par catégorie, plus le nuage de mots et les récits représentatifs du thème sélectionné, parmi les 81 thèmes / 11 catégories), une **analyse thématique** (importance et tendance de chaque thème), une **carte temporelle**, une page de **signaux faibles**, et une page de **prédiction** où le classifieur s'exécute directement dans le navigateur sur un récit saisi. L'objectif est de rendre les résultats consultables par un lecteur non spécialiste du code.

7 README – lancement du dashboard

Pour lancer le dashboard React en local :

```
cd frontend
npm install
npm run dev
```

L'application est ensuite disponible dans le navigateur à l'adresse indiquée par Vite (généralement <http://localhost:5173>).

Pour lancer la version Streamlit :

```
streamlit run dashboard/app.py
```

8 Implications et recommandations

Les résultats se traduisent en pistes concrètes pour la sécurité aérienne :

- **Équipement (43,8 %) et maintenance.** Le volume des signalements techniques plaide pour une **maintenance prédictive** exploitant ces remontées.




Figure 5 – Répartition des principales anomalies par année (intensité relative à chaque type) : une ligne qui se réchauffe vers la droite indique un type d’incident en progression.

- **Incursions au sol (en hausse).** Cohérentes avec la densification du trafic, elles justifient un renforcement des procédures de roulage, du marquage des aires de manœuvre et de la vigilance ATC au sol.
- **Fumées et odeurs en cabine (en hausse).** Appellent une surveillance accrue de la qualité de l’air et des circuits de prélèvement.
- **Marchandises dangereuses (en hausse).** Justifient un contrôle documentaire renforcé du fret.
- **Risques émergents (drones, GPS, lithium).** Recommandent une veille dédiée et l’évaluation de moyens de détection et de contre-mesures.

9 Conclusion

Ce projet a montré qu’il est possible d’exploiter automatiquement un très grand volume de rapports d’incidents aéronautiques afin d’en extraire des informations utiles pour la sécurité aérienne. À partir d’un corpus de 125 763 rapports NASA ASRS, une chaîne complète de traitement NLP a été développée, depuis le prétraitement des récits jusqu’à leur analyse et leur visualisation.

L’approche non supervisée a permis d’identifier automatiquement 81 thèmes d’incidents, regroupés ensuite en 11 catégories métier facilitant l’interprétation des résultats. Les métriques obtenues confirment la qualité du regroupement, avec un score de silhouette de 0,590 pour HDBSCAN, supérieur à celui obtenu avec K-Means. La classification supervisée des anomalies a atteint un F1 pondéré de 0,615, démontrant qu’une partie importante des catégories d’incidents peut être prédite à partir du contenu textuel des rapports.

L’analyse a également mis en évidence plusieurs tendances importantes, notamment la prédominance des incidents liés aux équipements et systèmes, l’augmentation des incursions au sol ainsi que l’émergence de problématiques plus récentes telles que les drones, le brouillage GPS ou le transport de batteries au lithium. La détection de signaux faibles a permis d’isoler des rapports atypiques susceptibles de révéler des risques émergents avant qu’ils ne deviennent fréquents.

Enfin, les résultats ont été intégrés dans un dashboard interactif, permettant d’explorer les thèmes identifiés, les évolutions temporelles des incidents et les signaux faibles détectés. Cette interface transforme un corpus volumineux et difficilement exploitable en un outil d’aide à la décision

accessible à des utilisateurs non spécialistes du traitement automatique du langage.

Au-delà des performances obtenues, ce projet illustre l'intérêt des techniques de Machine Learning et de NLP pour l'analyse de données de sécurité à grande échelle. Des perspectives d'amélioration existent, notamment l'utilisation de modèles de langage spécialisés dans le domaine aéronautique, l'intégration d'approches de classification multi-labels et l'exploitation de données complémentaires afin d'améliorer encore la détection précoce des risques et l'interprétation des incidents.