


Analyse automatique des rapports d'incidents NASA ASRS

Clustering thématique, classification des anomalies, signaux faibles
et dashboard d'aide à la décision

Rapport final académique

Mehdi Tidjani – [Étudiant 2] – [Étudiant 3]

Projection UMAP des rapports (couleur = catégorie)



Projection des 125 763 rapports ASRS dans l'espace sémantique

Données NASA ASRS – 125 763 rapports
Période juin 2002 – décembre 2025
Méthodes TF-IDF, embeddings, UMAP, HDBSCAN, LDA, SVM
Livrables notebook, pipeline Python, dashboard Streamlit, dashboard React, rapport PDF
Dépôt <https://github.com/devMehdi485/asrs-ml>

Table des matières

1	Contexte et problématique	2
2	Objectifs	2
3	Méthodologie	2
3.1	Données	2
3.2	Prétraitement	2
3.3	Vectorisation	3
3.4	Clustering thématique	3
3.5	Modélisation des sujets	3
3.6	Classification supervisée	3
3.7	Détection des signaux faibles	4
4	Résultats	4
4.1	Structure thématique	4
4.2	Qualité des clusters	5
4.3	Classification	6
4.4	Tendances temporelles	6
4.5	Signaux faibles	7
5	Dashboard	8
6	Limites et perspectives	9
7	Conclusion	9

1 Contexte et problématique

La base NASA ASRS (*Aviation Safety Reporting System*) regroupe des rapports d'incidents aériens déclarés volontairement par des pilotes, contrôleurs et autres acteurs opérationnels. Chaque rapport contient un récit en texte libre qui explique le contexte, le déroulement de l'incident et les facteurs ayant contribué à l'événement.

Le projet porte sur 125 763 rapports couvrant la période de juin 2002 à décembre 2025. Le volume rend impossible une lecture manuelle complète. La difficulté principale est donc de transformer ces récits non structurés en informations exploitables : causes récurrentes, groupes de rapports similaires, catégories d'anomalies et signaux rares.

La problématique traitée est la suivante : comment exploiter automatiquement les récits ASRS pour aider à identifier les tendances de sécurité aérienne et les risques émergents ?

2 Objectifs

Le projet poursuit cinq objectifs opérationnels :

1. identifier automatiquement les causes récurrentes présentes dans les récits ;
2. regrouper les rapports similaires par thématique ;
3. classer les catégories d'anomalies à partir du texte ;
4. détecter des signaux faibles et des risques émergents ;
5. fournir un dashboard interactif permettant d'explorer les résultats.

Le résultat attendu n'est pas seulement un modèle, mais une chaîne complète : données brutes, traitements NLP, résultats interprétables et interface de consultation.

3 Méthodologie

3.1 Données

Entrée. Les données d'entrée sont les rapports ASRS exportés au format CSV. Le jeu utilisé contient 125 763 rapports. Les champs principaux sont le récit (*narrative*), le synopsis, la date, la phase de vol, le type d'anomalie et des métadonnées techniques.

Traitement. Le pipeline charge le fichier ASRS, repère automatiquement les colonnes utiles et fusionne les champs textuels pour obtenir un texte d'analyse par rapport. Les métadonnées sont conservées pour interpréter les résultats par phase de vol, date ou type d'anomalie.

Sortie. Cette étape produit un corpus de 125 763 textes associés à leurs métadonnées. La période couverte va de 2002-06 à 2025-12. Les phases les plus représentées sont *Cruise* (20 738 rapports), *Parked* (15 493), *Initial Approach* (12 880), *Taxi* (12 294) et *Climb* (11 132).

3.2 Prétraitement

Entrée. Le prétraitement part des récits bruts et des synopsis extraits du fichier ASRS.

Traitement. Les textes sont nettoyés afin de retirer le bruit lié au format des rapports : marqueurs de désidentification, casse, ponctuation non informative, mots très fréquents et formes lexicales redondantes. Une lemmatisation est appliquée pour rapprocher les variantes d'un même terme.

Sortie. Cette étape produit un corpus nettoyé. Il sert ensuite à calculer les représentations numériques des rapports et à extraire les mots caractéristiques des thèmes.

3.3 Vectorisation

Entrée. La vectorisation utilise le corpus nettoyé.

Traitement. Les rapports ont été transformés en vecteurs TF-IDF afin d'identifier les mots et bigrammes les plus caractéristiques de chaque incident. En parallèle, des embeddings de phrases `all-MiniLM-L6-v2` ont été calculés pour représenter le sens global des récits. Un modèle `Word2Vec` entraîné sur le corpus a également été utilisé pour vérifier la cohérence du vocabulaire aéronautique.

Sortie. La sortie est double : une matrice TF-IDF pour la classification et l'interprétation, et une matrice d'embeddings pour le clustering thématique. Les voisins `Word2Vec` confirment la cohérence du vocabulaire : `runway` est proche de `rwy` (0,84) et `taxiway` (0,65), `weather` de `thunderstorm` (0,76) et `storm` (0,74), `altitude` de `alt` (0,70) et `descended` (0,67).

3.4 Clustering thématique

Entrée. Le clustering utilise les embeddings de phrases, qui rapprochent les rapports décrivant des situations similaires même si les mots exacts diffèrent.

Traitement. Les embeddings sont réduits avec UMAP pour obtenir un espace plus compact. Deux approches sont comparées sur ce même espace : K-Means et HDBSCAN. K-Means produit des groupes fixes, tandis que HDBSCAN isole aussi les rapports trop atypiques pour être rattachés clairement à un groupe.

Sortie. HDBSCAN est retenu. Il produit 81 thèmes et 32,5 % de points classés comme bruit. Ces points ne sont pas supprimés : ils sont réutilisés dans la détection de signaux faibles. Les 81 thèmes sont ensuite regroupés en 11 catégories métier pour faciliter la lecture.

3.5 Modélisation des sujets

Entrée. La modélisation des sujets utilise le corpus nettoyé et les représentations lexicales.

Traitement. Une modélisation LDA est appliquée pour obtenir une lecture complémentaire aux clusters. Le clustering affecte chaque rapport à un groupe principal ; LDA met en évidence des ensembles de mots qui reviennent ensemble dans le corpus.

Sortie. Le modèle LDA obtient une cohérence c_v de 0,5698. Les sujets retrouvés recouvrent les grandes situations opérationnelles du corpus : approche, altitude, piste, cabine, moteur, carburant, maintenance, turbulence, taxi et communications ATC.

3.6 Classification supervisée

Entrée. La classification utilise les vecteurs TF-IDF et les catégories d'anomalies ASRS. Les huit anomalies les plus représentées sont conservées pour limiter le déséquilibre extrême entre classes.

Traitement. Deux modèles linéaires sont entraînés : régression logistique et SVM linéaire. La prédiction repose sur l'ensemble du récit vectorisé, et non sur quelques mots isolés.

Sortie. Les modèles produisent une catégorie d'anomalie probable pour chaque rapport. Le SVM linéaire obtient le meilleur F1 pondéré : 0,615.

3.7 Détection des signaux faibles

Entrée. La détection utilise les représentations réduites, les distances aux groupes et les rapports considérés comme bruit par HDBSCAN.

Traitement. Un score d'atypicité est calculé avec Isolation Forest et complété par l'information issue du clustering. Les rapports rares, isolés ou associés à des thèmes émergents sont remontés dans une liste de surveillance.

Sortie. Le pipeline identifie 2 463 rapports atypiques. Les thèmes les plus visibles concernent les drones, le brouillage GPS, les batteries lithium et les outils de navigation électronique. Ces résultats servent à repérer des risques peu fréquents mais importants pour la veille de sécurité.

4 Résultats

4.1 Structure thématique

Le clustering fait émerger 81 thèmes regroupés en 11 catégories métier. La catégorie la plus importante est *Équipement & systèmes*, avec 37 179 rapports, 21 thèmes et 43,8 % du corpus thématisé. Elle regroupe notamment les pannes avioniques, les trains d'atterrissage, les pannes hydrauliques, la pressurisation, les instruments et les systèmes automatiques.

Table 1 – Répartition des thèmes par catégorie métier.

Catégorie	Rapports	Thèmes	Part
Équipement & systèmes	37 179	21	43,8 %
Sol & piste	11 256	7	13,3 %
Trajectoire & altitude	6 633	10	7,8 %
Cabine & sécurité	6 190	8	7,3 %
Moteur & carburant	5 457	11	6,4 %
Conflits de trafic	4 875	6	5,7 %
Météo & environnement	4 612	6	5,4 %
Communications & ATC	3 153	5	3,7 %
Signaux émergents	2 967	5	3,5 %
Chargement & hazmat	1 959	1	2,3 %
Facteurs humains	591	1	0,7 %




Figure 1 – Répartition des incidents par catégorie métier.

Pour l'analyse de sécurité, cette structure montre que les rapports ASRS contiennent une forte densité de retours sur les systèmes avion et la maintenance. Les incidents au sol et sur piste forment le deuxième ensemble, ce qui met en évidence l'importance des phases de taxi, d'alignement et de circulation au sol.

Table 2 – Principaux thèmes extraits par HDBSCAN.

Cluster	Thème	Rapports	Part
0	Pannes avioniques & systèmes (jets régionaux)	22 258	26,2 %
72	Incursions & erreurs au sol (taxi/piste)	8 458	10,0 %
29	Fumée, odeurs & émanations en cabine	3 392	4,0 %
75	Conflits de trafic en circuit d'aérodrome	2 656	3,1 %
65	Turbulence de sillage	2 459	2,9 %
44	Maintenance & inspections	2 108	2,5 %
6	Chargement, masse & marchandises dangereuses	1 959	2,3 %
69	Proximité du terrain à l'approche (CFIT)	1 907	2,2 %
77	Coordination ATC & gestion des secteurs	1 858	2,2 %
42	Problèmes de train d'atterrissage	1 804	2,1 %




Figure 2 – Douze thèmes les plus volumineux.

4.2 Qualité des clusters

Table 3 – Comparaison K-Means / HDBSCAN sur les embeddings réduits par UMAP.

Modèle	Clusters	Bruit	Silhouette	Davies-Bouldin	ARI	Pureté
K-Means	15	0,0 %	0,382	0,9447	0,0410	0,1326
HDBSCAN	81	32,5 %	0,5897	0,5747	0,0127	0,1651

HDBSCAN est retenu car il sépare mieux les groupes : la silhouette est plus élevée et l'indice Davies-Bouldin est plus faible. Le taux de bruit de 32,5 % est cohérent avec la nature des rapports ASRS : certains récits décrivent des situations très spécifiques, rarement répétées dans le corpus.

La pureté par rapport aux anomalies officielles reste modérée. Ce résultat est attendu : les anomalies ASRS sont des codes administratifs, tandis que les clusters regroupent des situations décrites dans les récits. Un même code peut donc couvrir plusieurs contextes opérationnels différents.




Figure 3 – Projection UMAP des rapports et structure des groupes thématiques.

4.3 Classification

Table 4 – Performance de classification sur les huit anomalies principales.

Modèle	F1 macro	F1 pondéré
Régression logistique	0,518	0,606
SVM linéaire	0,517	0,615

Le SVM linéaire obtient le meilleur score global avec un F1 pondéré de 0,615. La performance est correcte pour une tâche fondée sur du texte libre et des catégories parfois proches.

Les classes les mieux reconnues sont celles dont le vocabulaire est plus spécifique : problèmes ATC, équipements critiques et conflits NMAC. Les classes liées aux déviations procédurales sont plus difficiles, car elles peuvent apparaître dans des contextes très différents.

4.4 Tendances temporelles

L’analyse temporelle agrège les rapports par mois et par année. Elle permet de repérer les volumes anormaux, les thèmes en hausse et les évolutions par type d’anomalie.

Plusieurs thèmes montrent une progression récente : les incursions et erreurs au sol (+5,0 %), les fumées et odeurs en cabine (+3,4 %), les marchandises dangereuses (+4,2 %) et les rencontres avec drones ou objets en vol (+2,5 %). Pour la sécurité aérienne, ces tendances orientent la veille vers




Figure 4 – Mots caractéristiques de plusieurs thèmes principaux.

Table 5 – Détail des performances par classe pour le modèle reporté.

Classe	Précision	Rappel	F1	Support
ATC Issue All Types	0,86	0,68	0,76	5 406
Aircraft Equipment Problem Critical	0,80	0,58	0,67	8 059
Aircraft Equipment Problem Less Severe	0,53	0,44	0,48	4 804
Conflict Airborne Conflict	0,24	0,28	0,26	695
Conflict Ground Conflict	0,52	0,64	0,58	1 069
Conflict NMAC	0,65	0,73	0,69	1 312
Deviation / Discrepancy – Procedural FAR	0,12	0,74	0,21	786
Deviation / Discrepancy – Published Material / Policy	0,52	0,48	0,50	2 587
Accuracy			0,57	24 718
Macro avg	0,53	0,57	0,52	24 718
Weighted avg	0,68	0,57	0,61	24 718

les opérations au sol, la qualité de l'air cabine, la gestion du fret et l'intégration de nouveaux objets dans l'espace aérien.

4.5 Signaux faibles

La détection de signaux faibles fait ressortir 2 463 rapports atypiques. Les thèmes émergents identifiés sont :

Ces signaux ne représentent pas les volumes les plus importants du corpus, mais ils sont utiles pour la veille. Les drones et les brouillages GPS indiquent des risques liés à l'évolution de l'environnement opérationnel. Les batteries lithium et les problèmes de chargement renvoient à des enjeux de transport de marchandises dangereuses.




Figure 5 – Volume mensuel de rapports ASRS sur la période étudiée.




Figure 6 – Heatmap anomalie par année.

5 Dashboard

Deux interfaces ont été produites pour exploiter les résultats sans relancer les traitements :

- un dashboard Streamlit, orienté analyse rapide et exploration des artefacts Python ;
- un dashboard React/TypeScript, alimenté par un export JSON statique des résultats.

Le dashboard React contient six pages : synthèse exécutive, vue opérationnelle, exploration des clusters, analyse thématique, carte temporelle et signaux faibles. Les données affichées proviennent du fichier `frontend/public/data/asrs.json`, ce qui permet de consulter les résultats sans recalculer les modèles.

Le dashboard remplit trois fonctions principales. D'abord, il donne une vue globale des volumes, catégories et principaux thèmes. Ensuite, il permet d'inspecter un cluster : mots-clés, taille, phase dominante, anomalie dominante et exemples de rapports. Enfin, il sert à surveiller les tendances temporelles et les rapports atypiques.

Table 6 – Thèmes associés aux signaux faibles et risques émergents.

Thème	Rapports	Part	Tendance
Rencontres avec drones / objets en vol	1 221	1,4 %	en hausse (+2,5 %)
Brouillage GPS & anomalies de navigation	626	0,7 %	stable (+1,4 %)
Batteries lithium (hazmat)	471	0,6 %	stable (+1,2 %)
Drones : violations d'espace (UAS)	422	0,5 %	stable (+1,1 %)
EFB / iPad & bases de données	227	0,3 %	stable (-0,2 %)

6 Limites et perspectives

Les résultats doivent être interprétés avec plusieurs limites.

Le corpus ASRS repose sur des déclarations volontaires. Il reflète donc les incidents signalés, pas l'ensemble des incidents survenus. Les données sont aussi désidentifiées, ce qui protège les personnes mais retire certains éléments de contexte.

Les classes d'anomalies sont fortement déséquilibrées. Cela explique une partie des difficultés de classification, en particulier pour les classes rares. Certains rapports peuvent aussi relever de plusieurs anomalies, alors que la classification mise en place reste centrée sur une cible principale.

Enfin, certains grands clusters restent hétérogènes. Le cluster des pannes avioniques et systèmes, par exemple, contient 22 258 rapports. Il donne une bonne vue d'ensemble, mais il mériterait une sous-segmentation plus fine.

Les perspectives principales sont :

- tester une classification multi-étiquettes pour mieux traiter les rapports à causes multiples ;
- utiliser des embeddings spécialisés sur le vocabulaire aéronautique ;
- sous-segmenter les clusters les plus volumineux ;
- croiser les signaux faibles avec des données externes, par exemple trafic, météo ou zones aéroportuaires ;
- ajouter un suivi automatique des nouveaux rapports dans le dashboard.

7 Conclusion

Le projet a permis de construire une chaîne NLP complète appliquée à 125 763 rapports NASA ASRS. Les récits bruts ont été nettoyés, vectorisés, regroupés en 81 thèmes, organisés en 11 catégories métier, puis exploités pour la classification, l'analyse temporelle et la détection de signaux faibles.

Les résultats principaux sont les suivants : HDBSCAN obtient 81 clusters avec une silhouette de 0,5897 ; LDA atteint une cohérence de 0,5698 ; le meilleur classifieur atteint un F1 pondéré de 0,615 ; 2 463 rapports atypiques sont remontés comme signaux faibles. Les thèmes dominants concernent les équipements et systèmes, les opérations au sol, les trajectoires, la cabine, le moteur et les conflits de trafic.

Le dashboard final rend ces résultats consultables par un utilisateur non spécialiste du code. Il transforme un corpus massif de récits en un outil d'exploration utile pour suivre les causes récurrentes, comparer les thèmes et repérer les risques émergents.