


Analyse NLP des rapports d'incidents de sécurité aérienne

Extraction des causes récurrentes, classification des anomalies
et détection de signaux faibles sur la base **NASA ASRS**

Rapport technique

Projection UMAP des rapports (couleur = catégorie)



Projection sémantique des 125 763 rapports, colorée par catégorie d'incident

Jeu de données	NASA ASRS — 125 763 rapports (2002–2025)
Cadre	Projet A3 — équipe de 3 étudiants 3–4 semaines
Livrables	Pipeline NLP · Dashboards (Streamlit & React) · Rapport
Dépôt	https://github.com/devMehdi485/asrs-ml

Résumé

Le présent rapport documente une chaîne complète de traitement automatique du langage naturel (NLP) appliquée à 125 763 rapports d'incidents de la base *Aviation Safety Reporting System* (ASRS) de la NASA. L'objectif est de transformer un volume massif de récits en texte libre en information structurée et exploitable pour la sécurité aérienne. La méthodologie combine un prétraitement linguistique, une vectorisation hybride (TF-IDF, word2vec et embeddings de phrases), un clustering thématique (comparaison K-Means / HDBSCAN), une modélisation de sujets (LDA) et une classification supervisée (régression logistique, SVM). L'analyse fait émerger 81 thèmes regroupés en 11 catégories métier, atteint un score F1 pondéré de 0,615 en classification, et identifie des signaux faibles émergents (drones, brouillage GPS, batteries au lithium). Les résultats sont interprétés au regard des enjeux opérationnels de la sécurité aérienne.

Table des matières

1	Contexte et problématique	2
2	Objectifs	2
3	Méthodologie	2
3.1	Données et prétraitement	2
3.2	Vectorisation	3
3.3	Clustering thématique	3
3.4	Modélisation de sujets (LDA)	3
3.5	Classification supervisée	3
3.6	Détection de signaux faibles et analyse temporelle	4
4	Résultats	4
4.1	Structure thématique du corpus	4
4.2	Cohérence des clusters	4
4.3	Validation sémantique (word2vec) et modélisation LDA	5
4.4	Classification des anomalies	5
5	Discussion	6
5.1	Tendances temporelles	6
5.2	Signaux faibles	6
6	Limites et perspectives	7
7	Conclusion	8

1 Contexte et problématique

L'*Aviation Safety Reporting System* (ASRS), administré par la NASA depuis 1976, constitue l'un des plus anciens et des plus vastes dispositifs de retour d'expérience en sécurité aérienne. Il repose sur la soumission **volontaire et confidentielle**, par les pilotes, contrôleurs et techniciens, du récit des incidents observés ou vécus. En contrepartie d'une immunité partielle, les déclarants décrivent en langage naturel les événements ayant compromis, ou failli compromettre, la sécurité d'un vol. La base regroupe ainsi plusieurs centaines de milliers de témoignages, riches en informations sur les défaillances latentes du système aéronautique.

La valeur de cette ressource est largement reconnue, mais son exploitation se heurte à une difficulté majeure : l'information déterminante est contenue dans des **champs textuels non structurés**. Un récit type illustre la nature de cette donnée :

« About 40 minutes into the flight, the First Officer and I smelled a strong electrical smell in the cockpit...there was a 'haze' in the cabin air. We advised ATC and completed the QRH items for smoke... »

L'analyse manuelle d'un tel volume étant impossible à l'échelle, la problématique abordée est la suivante : **comment exploiter automatiquement ces récits afin d'extraire les causes récurrentes d'incidents, d'en classifier les types et de détecter les signaux faibles susceptibles de précéder des accidents ?** Le traitement automatique du langage naturel offre un cadre adapté à cette question, en permettant de structurer, regrouper et hiérarchiser l'information textuelle à grande échelle.

2 Objectifs

Le projet poursuit trois objectifs principaux, articulés autour des familles de techniques NLP attendues :

1. **Extraction des causes récurrentes** : faire émerger, sans supervision, les grands thèmes d'incidents présents dans le corpus (clustering et modélisation de sujets).
2. **Classification des anomalies** : prédire automatiquement la catégorie d'anomalie d'un rapport à partir de son seul contenu textuel (apprentissage supervisé).
3. **Détection de signaux faibles** : identifier les rapports atypiques décrivant des phénomènes rares et potentiellement précurseurs (détection d'anomalies).

Un objectif transversal d'**interprétabilité** encadre l'ensemble : les résultats doivent être restitués sous une forme intelligible pour des décideurs non spécialistes, ce qui motive la production de tableaux de bord et la labellisation métier des thèmes.

3 Méthodologie

Chaque étape de la chaîne de traitement est décrite ci-dessous, accompagnée de la justification du choix méthodologique retenu.

3.1 Données et prétraitement

L'étude porte sur un export de **125 763 rapports** (2002–2025). Les champs textuels (*narratives* des rapporteurs et synopsis) sont disponibles à 100 %, et les métadonnées clés sont très majoritairement renseignées (anomalie 99,7 %, phase de vol 95,9 %, type d'aéronef 98,9 %, date

100 %). Le format d'export présente une double ligne d'en-tête, traitée automatiquement par un module de chargement dédié.

Le prétraitement comprend la suppression des artefacts de désidentification (jetons **ZZZ**, **XXX**), la mise en minuscules, la tokenisation, le retrait des *stopwords* (anglais et liste métier aéronautique) puis la lemmatisation. Ce niveau de nettoyage se justifie par la sensibilité des méthodes de vectorisation à la qualité de l'entrée : les jetons de désidentification, omniprésents, et les termes génériques du domaine masqueraient le signal thématique s'ils étaient conservés.

3.2 Vectorisation

Trois représentations complémentaires sont employées, chacune répondant à un besoin distinct :

- **TF-IDF** (uni et bigrammes) : représentation creuse et interprétable. Son intérêt réside dans la possibilité d'identifier explicitement les termes caractéristiques d'un thème ou d'une classe ; elle sert de base à la classification et à la labellisation.
- **word2vec** entraîné sur le corpus : représentation dense capturant la proximité sémantique du vocabulaire spécialisé, utile pour valider la cohérence lexicale du domaine.
- **Embeddings de phrases** (**all-MiniLM-L6-v2**) : représentation contextuelle encodant le sens global d'un récit. Ce choix, qui constitue une amélioration par rapport aux seuls word2vec/GloVe, se justifie par la variabilité d'expression des déclarants : deux récits décrivant un même événement avec des formulations différentes sont rapprochés dans l'espace vectoriel, ce qui améliore sensiblement la cohérence du clustering.

3.3 Clustering thématique

Les embeddings de phrases sont d'abord réduits par **UMAP**, afin d'atténuer le bruit et de réduire le coût de calcul. Deux algorithmes de clustering sont ensuite **comparés sur les mêmes données** : K-Means (partitionnement en classes de tailles comparables) et HDBSCAN (regroupement par densité, avec gestion explicite du bruit). Cette comparaison, plutôt qu'un choix imposé a priori, permet une sélection objective fondée sur des métriques de cohérence. Une règle de décision est formalisée, assortie d'un garde-fou écartant toute solution dégénérée (nombre de clusters trop faible).

3.4 Modélisation de sujets (LDA)

Une modélisation **LDA** (Latent Dirichlet Allocation) complète le clustering. Les deux approches sont complémentaires : le clustering attribue chaque récit à un groupe unique, tandis que LDA décompose le corpus en sujets probabilistes, un même document pouvant relever de plusieurs sujets. La qualité des sujets est évaluée par la **cohérence** c_v .

3.5 Classification supervisée

Des modèles linéaires — **régression logistique** et **SVM linéaire** — sont entraînés sur la représentation TF-IDF pour prédire l'anomalie principale (catégories les plus fréquentes). Le choix de modèles linéaires se justifie par leur robustesse, leur rapidité et leur interprétabilité, propriétés jugées prioritaires devant un gain marginal de performance qu'apporteraient des modèles moins transparents.

3.6 Détection de signaux faibles et analyse temporelle

La détection de signaux faibles repose sur un **Isolation Forest** appliqué aux représentations réduites, complété par les points classés comme bruit par HDBSCAN. L'analyse temporelle agrège les volumes mensuels, détecte les pics par z-score et suit l'évolution de la part de chaque thème dans le temps.

4 Résultats

4.1 Structure thématique du corpus

L'analyse fait émerger **81 thèmes**, regroupés en **11 catégories métier** (figure 1). La répartition met en évidence une forte prédominance des incidents liés à l'**équipement et aux systèmes** (43,8 % du corpus), devant les incidents au sol et sur piste (13,3 %) et les écarts de trajectoire ou d'altitude (7,8 %).




FIGURE 1 – Répartition des incidents par catégorie métier.

Cette prédominance des signalements liés à l'équipement ne traduit pas nécessairement une fréquence accrue de pannes, mais une **propension élevée des équipages à signaler tout dysfonctionnement technique**. Sur le plan opérationnel, ce constat conforte la pertinence d'une politique de **maintenance proactive et prédictive**, susceptible d'exploiter ce volume de signalements pour anticiper les défaillances.

Chaque thème est associé à un libellé métier et à des termes saillants (figure 3), ce qui en assure la lisibilité.

4.2 Cohérence des clusters

TABLE 1 – Comparaison K-Means / HDBSCAN sur les données réduites (UMAP).

Modèle	Clusters	Silhouette	Davies-Bouldin	Bruit	Pureté
K-Means	15	0,382	0,945	0 %	0,133
HDBSCAN (retenu)	81	0,590	0,575	32 %	0,165

Le modèle **HDBSCAN** est retenu : il présente une silhouette supérieure (0,590 contre 0,382)




FIGURE 2 – Douze thèmes d'incidents les plus volumineux.

et un indice de Davies-Bouldin plus faible, signe d'une meilleure séparation des groupes. La concordance modérée avec les catégories d'anomalies officielles (pureté, ARI) s'explique par la granularité supérieure des thèmes sémantiques obtenus, plus fins que les catégories codées par les analystes. Les points classés comme bruit (32 %) sont exploités pour la détection de signaux faibles.

4.3 Validation sémantique (word2vec) et modélisation LDA

Le modèle word2vec entraîné sur le corpus restitue des proximités sémantiques cohérentes avec le domaine (tableau 2), ce qui valide la qualité des données et du prétraitement. La cohérence moyenne du modèle LDA atteint $c_v = 0,57$, indiquant des sujets lexicalement homogènes.

TABLE 2 – word2vec — voisins les plus proches (similarité cosinus).

Terme	Voisins les plus proches
runway	rw (0,84), taxiway (0,65), intersecting (0,59), midfield (0,59)
engine	eng (0,69), feathered (0,57), magneto (0,54), crossbleed (0,54)
weather	thunderstorm (0,76), storm (0,74), bkn (0,68), forecast (0,66)
altitude	alt (0,70), descended (0,67), descend (0,65), level (0,64)

4.4 Classification des anomalies

TABLE 3 – Performance de la classification (top-8 anomalies, TF-IDF).

Modèle	F1 macro	F1 pondéré
Régression logistique	0,518	0,606
SVM linéaire	0,517	0,615

Les résultats indiquent une performance satisfaisante au regard de la difficulté de la tâche (8 catégories, texte libre), avec un F1 pondéré atteignant 0,615. Les classes au vocabulaire spécifique




FIGURE 3 – Nuages de mots (c-TF-IDF) des quatre principaux thèmes.

sont les mieux reconnues (*ATC Issue*, $F1 = 0,76$; *NMAC*, 0,69 ; *Aircraft Equipment Problem Critical*, 0,67), tandis que les classes rares et les rapports relevant de plusieurs anomalies demeurent plus difficiles à discriminer.

5 Discussion

5.1 Tendances temporelles

L'analyse temporelle (figures 4 et 5) révèle plusieurs thèmes en progression récente, dont l'interprétation présente un intérêt opérationnel direct :

- **Incursions et erreurs au sol — en hausse.** Cette évolution est cohérente avec la **densification du trafic** et la saturation croissante des plateformes aéroportuaires, qui multiplient les situations de croisement et les risques d'erreur sur les voies de circulation.
- **Fumées et odeurs en cabine — en hausse.** Cette tendance appelle une vigilance renforcée sur les circuits de prélèvement et la qualité de l'air cabine (*fume events*).
- **Marchandises dangereuses — en hausse.** Cette progression est cohérente avec la croissance du fret aérien et soulève des enjeux de conformité documentaire et de sûreté.

5.2 Signaux faibles

La détection d'anomalies fait remonter des phénomènes rares mais à fort enjeu, notamment les rencontres avec des **drones**, le **brouillage du signal GPS** et les **batteries au lithium**. Ces thématiques, quasi absentes au début de la période étudiée, illustrent l'apparition de nouvelles classes de risques. Un récit représentatif en témoigne :

« Approach control advised there was unauthorized drone use in the area... I observed a drone pass just left of the aircraft, approximately 20 feet from our left wing. »




FIGURE 4 – Volume mensuel de rapports (2002–2025).




FIGURE 5 – Heatmap : type d'anomalie × année.

De tels rapports, noyés dans la masse, échapperaient à une analyse manuelle. Leur remontée automatique constitue l'apport principal du dispositif de détection : elle permet d'identifier précocement des risques émergents avant qu'ils ne se traduisent par des événements plus graves. L'impact potentiel sur la sécurité aérienne est donc significatif, tant pour l'orientation des programmes de prévention que pour la veille réglementaire.

6 Limites et perspectives

Plusieurs limites doivent être prises en compte dans l'interprétation des résultats :

- **Déséquilibre des classes.** La distribution des anomalies est fortement inégale, ce qui pénalise la reconnaissance des classes rares malgré une pondération équilibrée à l'entraînement.
- **Données désidentifiées.** La suppression des identifiants et des localisations entraîne une perte de contexte potentiellement informatif.
- **Biais de déclaration.** Le caractère volontaire de l'ASRS implique que le corpus reflète les incidents *signalés*, et non l'ensemble des incidents survenus.
- **Hétérogénéité d'un méga-cluster.** Le regroupement relatif à l'équipement avionique demeure plus difficile à interpréter finement.

Plusieurs pistes d'amélioration sont envisageables. L'emploi de **BERTopic** permettrait une thématisation de bout en bout intégrant nativement l'analyse temporelle. Le recours à des **embed-**

dings spécialisés, ré-entraînés sur un corpus aéronautique, améliorerait la séparation des thèmes techniques. Une **classification multi-étiquettes** rendrait mieux compte des rapports relevant simultanément de plusieurs anomalies. Enfin, le croisement des signaux faibles avec des données externes (trafic, météorologie) ouvrirait la voie à une analyse à visée prédictive.

7 Conclusion

Le projet met en évidence la faisabilité et la valeur d'une exploitation automatisée des récits d'incidents ASRS. À partir de 125 763 rapports en texte libre, la chaîne de traitement produit 81 thèmes interprétables regroupés en 11 catégories métier, un modèle de classification opérationnel (F1 pondéré de 0,615), un dispositif de détection de signaux faibles et deux tableaux de bord interactifs restituant l'ensemble des résultats.

Au-delà des performances mesurées, l'apport central du travail réside dans la **transformation de récits bruts en information structurée et exploitable**. En rendant visibles les causes récurrentes, les tendances temporelles et les risques émergents, l'approche proposée constitue un outil d'aide à la décision pour les acteurs de la sécurité aérienne, et démontre la pertinence du traitement automatique du langage naturel pour la valorisation des bases de retour d'expérience.