


Quand les récits de pilotes deviennent une intelligence de sécurité aérienne

Analyse automatique de 125 763 rapports d'incidents de la base NASA ASRS

Projection UMAP des rapports (couleur = catégorie)



Carte sémantique des 125 763 récits, regroupés par catégorie d'incident

Projet	Analyse NLP des rapports d'incidents de sécurité aérienne
Données	NASA ASRS — 125 763 rapports (2002–2025)
Équipe	3 étudiants 3–4 semaines
Dépôt & dashboards	https://github.com/devMehdi485/asrs-ml

Table des matières

1	Contexte et problématique	2
2	Objectifs	2
3	Méthodologie : mes choix et pourquoi	2
3.1	Prétraitement : nettoyer sans dénaturer	2
3.2	Vectorisation : trois représentations complémentaires	3
3.3	Clustering : découvrir les thèmes, et choisir avec méthode	3
3.4	LDA : une seconde lecture des thèmes	3
3.5	Classification : prédire le type d'incident	3
4	Résultats et interprétation	3
4.1	Une cartographie en 81 thèmes et 11 familles	4
4.2	Des thèmes que l'on peut nommer et comprendre	5
4.3	Cohérence des clusters : le choix de HDBSCAN, assumé	5
4.4	word2vec : la preuve que le modèle « comprend » le domaine	6
4.5	Classification : un modèle qui se défend	6
5	Discussion : tendances et signaux faibles	6
5.1	Ce que le temps révèle	6
5.2	Les signaux faibles : là où se cachent les risques de demain	6
6	Limites et perspectives	7
7	Conclusion	8

1 Contexte et problématique

Quand je me suis penché sur ce projet, une chose m’a immédiatement frappé : l’aviation est l’un des rares domaines où l’on a institutionnalisé le fait de *raconter ses erreurs*. Depuis 1976, la NASA gère l’*Aviation Safety Reporting System* (ASRS), un système où pilotes, contrôleurs et techniciens déposent **volontairement et de manière confidentielle** le récit des incidents qu’ils vivent ou observent. En échange d’une immunité partielle, ils décrivent, avec leurs propres mots, ce qui s’est presque mal passé. Le résultat est une base de plusieurs centaines de milliers de **témoignages humains** sur les failles du système aérien.

Pour bien saisir la matière première, voici un extrait authentique d’un de ces récits :

« About 40 minutes into the flight, the First Officer and I smelled a strong electrical smell in the cockpit. We called the Flight Attendant and asked if she also smelled it. She said that she did and that there was a ‘haze’ in the cabin air. We advised ATC and completed the QRH items for smoke. . . »

On y entend une voix, une chronologie, une décision. C’est précisément ce qui fait la richesse — et la difficulté — de cette base : l’information cruciale est enfouie dans du **texte libre**, non structuré. Or personne ne peut lire, mémoriser et recouper 125 000 récits. **Voilà ma problématique** : comment faire *parler* automatiquement cette masse de témoignages pour en extraire ce qui compte vraiment pour la sécurité — les causes qui reviennent, les types d’incidents, et surtout les signaux faibles, ces rares récits atypiques qui pourraient annoncer les accidents de demain ?

2 Objectifs

J’ai construit mon projet autour de trois questions concrètes, qui correspondent à trois familles de techniques NLP :

1. **Extraire les causes récurrentes.** De quoi parlent réellement les pilotes ? Je veux faire émerger, sans a priori, les grands *thèmes* d’incidents (clustering non supervisé + modélisation de sujets).
2. **Classifier les types d’incidents.** À partir du seul texte, peut-on *prédire* la catégorie d’anomalie ? (classification supervisée).
3. **Détecter les signaux faibles.** Quels rapports sortent du lot, décrivent quelque chose de rare et potentiellement précurseur ? (détection d’anomalies).

À cela j’ai ajouté une exigence transversale : que tout soit **interprétable** et **exploitable**. Un cluster nommé « cluster 37 » ne sert à personne ; un thème nommé « Problèmes de train d’atterrissage » parle à un responsable sécurité. C’est le fil rouge de tout le projet, et la raison pour laquelle j’ai livré deux dashboards.

3 Méthodologie : mes choix et pourquoi

Je détaille ici chaque étape *et* la justification de mes décisions, car c’est là que se joue la pertinence du travail.

3.1 Prétraitement : nettoyer sans dénaturer

Les récits ASRS sont désidentifiés : les noms propres sont remplacés par des marqueurs comme ZZZ ou XXX. Mon premier réflexe a été de les retirer, car ces jetons, ultra-fréquents, auraient pollué toutes mes statistiques de mots. J’ai ensuite appliqué une chaîne classique — minuscules,

tokenisation, suppression des *stopwords* — en y ajoutant une **liste de stopwords métier** (« aircraft », « flight », « pilot »...) : ces mots sont partout et ne discriminent rien. Enfin, j'ai **lemmatisé** pour regrouper « engines », « engine », « engined » sous une seule forme. *Pourquoi ce soin ?* Parce qu'en NLP, la qualité du résultat dépend d'abord de la qualité de l'entrée : un bon nettoyage vaut souvent mieux qu'un modèle sophistiqué.

3.2 Vectorisation : trois représentations complémentaires

Un modèle ne lit pas du texte, il lit des nombres. J'ai donc transformé les récits de trois manières, chacune avec un rôle précis :

- **TF-IDF** — pondère chaque mot par sa rareté. Simple, rapide, et surtout **interprétable** : je peux dire *quels* mots caractérisent un thème. Je m'en sers pour la classification et pour nommer les clusters.
- **word2vec** (entraîné sur mon corpus) — apprend la *sémantique* du vocabulaire aéronautique. Le tableau 2 montre qu'il a vraiment « compris » le domaine, ce qui m'a rassuré sur la cohérence des données.
- **Embeddings de phrases** (all-MiniLM-L6-v2) — encodent le *sens global* d'un récit, pas seulement des mots isolés. *Pourquoi ce choix plutôt que le word2vec/GloVe du brief ?* Parce que deux pilotes peuvent décrire le même incident avec des mots différents ; un modèle de phrases les rapproche quand même. C'est ce qui donne des clusters nettement plus cohérents — une amélioration assumée par rapport à l'attendu.

3.3 Clustering : découvrir les thèmes, et choisir avec méthode

J'ai réduit les embeddings avec **UMAP** (pour enlever le bruit et accélérer), puis j'ai **comparé deux algorithmes** au lieu d'en imposer un : K-Means (simple, clusters de tailles comparables) et HDBSCAN (basé sur la densité, capable d'isoler le « bruit »). Je ne voulais pas choisir au hasard : j'ai posé une **règle de décision explicite** fondée sur des métriques (tableau 1), avec un garde-fou refusant tout HDBSCAN qui s'effondrerait en deux ou trois gros blocs inutilisables. C'est exactement le piège dans lequel je suis tombé au premier essai (un paramètre mal réglé donnait 2 clusters) — l'avoir corrigé fait partie de la démarche.

3.4 LDA : une seconde lecture des thèmes

En complément du clustering, j'ai entraîné un modèle **LDA** (Latent Dirichlet Allocation). *Pourquoi doubler ?* Parce que LDA et clustering ne « voient » pas la même chose : le clustering regroupe des récits entiers, LDA décompose le corpus en sujets probabilistes (un récit peut relever de plusieurs sujets). La **cohérence c_v de 0,57** obtenue me confirme que les sujets tiennent lexicalement la route.

3.5 Classification : prédire le type d'incident

Enfin, j'ai entraîné des modèles **supervisés** (régression logistique et SVM linéaire) pour prédire l'anomalie principale à partir du texte. J'ai volontairement choisi des modèles linéaires sur TF-IDF : ils sont **rapides, robustes et interprétables** (on peut lire les mots qui font pencher la décision), ce qui compte plus, ici, qu'un gain marginal de précision avec une « boîte noire ».

4 Résultats et interprétation

4.1 Une cartographie en 81 thèmes et 11 familles

Le pipeline fait émerger **81 thèmes** fins, que j’ai regroupés en **11 catégories métier** (figure 1). La structure n’est pas anodine : à elle seule, la famille **Équipement & systèmes** représente **43,8 %** des rapports.




FIGURE 1 – Répartition des incidents par catégorie métier.

Comment je lis ce résultat. Cette domination de l’équipement ne veut pas dire que les avions tombent en panne sans cesse ; elle traduit surtout que **les équipages signalent massivement le moindre dysfonctionnement technique**. Pour un exploitant, c’est un argument fort en faveur d’une **maintenance proactive** et prédictive : la matière existe pour anticiper les pannes plutôt que les subir.




FIGURE 2 – Les douze thèmes d’incidents les plus volumineux.

4.2 Des thèmes que l'on peut nommer et comprendre

Le plus important, à mes yeux, c'est que chaque thème est **lisible**. La figure 3 montre les nuages de mots des quatre principaux ; derrière chacun, il y a une réalité opérationnelle concrète. Par exemple, le thème « **Incursions & erreurs au sol** » (10 % du corpus, en hausse) rassemble des récits comme :

« *After landing we got an immediate clearance to cross the runway at taxiway 1...Before entering the runway environment, I looked...* »




FIGURE 3 – Nuages de mots (c-TF-IDF) des quatre principaux thèmes.

4.3 Cohérence des clusters : le choix de HDBSCAN, assumé

TABLE 1 – Comparaison K-Means vs HDBSCAN sur les mêmes données réduites (UMAP).

Modèle	Clusters	Silhouette	Davies-Bouldin	Bruit	Pureté
K-Means	15	0,382	0,945	0 %	0,133
HDBSCAN (retenu)	81	0,590	0,575	32 %	0,165

J'ai retenu **HDBSCAN** : meilleure silhouette (0,590 contre 0,382) et meilleur Davies-Bouldin. Un point que je tiens à défendre honnêtement : son alignement avec les catégories d'anomalies officielles (pureté/ARI) est *faible*, et c'est **normal**. Mes thèmes sont sémantiques (le vocabulaire des récits) et bien plus fins que la dizaine de catégories codées par les analystes : un même code « équipement » se décline chez moi en hydraulique, train, huile moteur, électrique... Ce n'est pas un défaut, c'est de la granularité. Quant aux 32 % de « bruit » d'HDBSCAN, loin de les jeter, je les **réutilise** comme matière première de la détection de signaux faibles.

TABLE 2 – word2vec — mots les plus proches (similarité cosinus) appris sur le corpus.

Mot	Voisins les plus proches
runway	rwyt (0,84), taxiway (0,65), intersecting (0,59), midfield (0,59)
engine	eng (0,69), feathered (0,57), magneto (0,54), crossbleed (0,54)
weather	thunderstorm (0,76), storm (0,74), bkn (0,68), forecast (0,66)
altitude	alt (0,70), descended (0,67), descend (0,65), level (0,64)

4.4 word2vec : la preuve que le modèle « comprend » le domaine

Ce tableau me sert d'argument de validation : sans aucune supervision, le modèle a appris que **runway** et **rwyt** sont synonymes, que **weather** évoque l'orage. La sémantique métier est bien capturée.

4.5 Classification : un modèle qui se défend

TABLE 3 – Classification du type d'incident (top-8 anomalies, TF-IDF).

Modèle	F1 macro	F1 pondéré
Régression logistique	0,518	0,606
SVM linéaire	0,517	0,615

Avec un **F1 pondéré de 0,615** sur 8 catégories et du texte 100 % libre, je considère le résultat solide. Les classes au vocabulaire net sont très bien reconnues (*ATC Issue* F1 = 0,76, *NMAC* 0,69). Pour le rendre tangible, j'ai même branché ce modèle dans le dashboard : on colle un récit, il prédit le type en direct.

5 Discussion : tendances et signaux faibles

5.1 Ce que le temps révèle

La dimension temporelle (figures 4 et 5) transforme une photo en film. Plusieurs thèmes sont en **hausse récente**, et leur interprétation métier est, selon moi, le cœur de la valeur du projet :

- **Incursions & erreurs au sol — en hausse.** Je l'interprète comme un symptôme de la **densification du trafic** et de la saturation des plateformes : plus d'avions au sol, plus de croisements, plus d'occasions d'erreur sur les taxiways.
- **Fumées / odeurs en cabine — en hausse.** Sujet sensible (qualité de l'air, *fume events*) qui mérite une vigilance accrue sur les circuits de prélèvement d'air.
- **Marchandises dangereuses — en hausse.** Cohérent avec l'explosion du fret et du e-commerce ; un enjeu de conformité documentaire et de sûreté.

5.2 Les signaux faibles : là où se cachent les risques de demain

C'est la partie qui me tient le plus à cœur. En isolant les récits les plus atypiques (Isolation Forest), je fais remonter des phénomènes **rare mais lourds de sens** : les rencontres avec des **drones**, le **brouillage GPS**, les **batteries au lithium**. Ces sujets étaient quasi inexistantes il y a quinze ans. Un témoignage résume tout l'intérêt de la démarche :

« *Approach control advised there was unauthorized drone use in the area...I observed a drone pass just left of the aircraft, approximately 20 feet from our left wing.* »




FIGURE 4 – Volume mensuel de rapports (2002–2025).




FIGURE 5 – Heatmap : type d'anomalie × année.

Un humain noyé sous 125 000 rapports passerait à côté. Mon système, lui, le fait remonter en tête de liste. **C'est exactement la promesse d'un détecteur de signaux faibles** : voir tôt ce qui deviendra peut-être, demain, une catégorie d'accidents à part entière.

6 Limites et perspectives

Je préfère exposer franchement les limites de mon travail — c'est ce qui en garantit la crédibilité.

- **Déséquilibre des classes.** Quelques types d'anomalies dominent ; les classes rares sont mal prédites. J'ai utilisé un *class_weight* équilibré, mais le problème reste réel.
- **Données désidentifiées.** La suppression des lieux et identifiants fait perdre un contexte parfois précieux (quel aéroport ? quel opérateur ?).
- **Biais de déclaration.** L'ASRS est volontaire : on n'y voit que ce que les gens *choisissent* de raconter. Ce n'est pas un échantillon représentatif de tous les incidents, mais de tous les incidents *signalés*.
- **Un méga-cluster hétérogène** (l'équipement avionique) reste plus difficile à interpréter finement.

Mes pistes d'amélioration. J'aimerais tester **BERTopic** (pipeline de thématisation de bout en bout, avec *topics-over-time* intégré), des **embeddings** spécialisés ré-entraînés sur le domaine

aéronautique pour mieux séparer le cluster d'équipement, et une **classification multi-étiquettes** (un récit décrit souvent plusieurs anomalies à la fois). Enfin, relier ces signaux faibles à des données externes (trafic, météo) ouvrirait la voie à une vraie analyse *prédictive*.

7 Conclusion

Au départ, j'avais 125 763 récits bruts, illisibles à l'échelle humaine. À l'arrivée, j'ai un système qui les **lit, regroupe, nomme, classe et surveille** : 81 thèmes interprétables en 11 familles, un modèle de classification opérationnel, une détection de signaux faibles, et deux dashboards qui rendent tout cela navigable — y compris pour un non-spécialiste.

Ce que je retiens, et ce que je défends devant ce jury, c'est moins la performance d'un algorithme que la **transformation** opérée : faire passer une montagne de témoignages humains du statut d'archive dormante à celui d'**intelligence de sécurité exploitable**. Les pilotes ont pris le temps de raconter. Mon travail consiste, modestement, à enfin les écouter tous à la fois.