


Analyse NLP des rapports d'incidents de sécurité aérienne

Extraction des causes récurrentes, classification des anomalies
et détection de signaux faibles sur la base **NASA ASRS**

Rapport technique d'ingénierie

TIDJANI Mehdi • FEUDJEU II LA GRACE • OUEDRAOGO
Martin

Projection UMAP des rapports (couleur = catégorie)



Projection sémantique des 125 763 rapports, colorée par catégorie d'incident

Jeu de données	NASA ASRS — 125 763 rapports (2002–2025)
Cadre	Projet A3 — équipe de 3 étudiants 3–4 semaines
Livrables	Pipeline NLP · Dashboards (Streamlit & React) · Rapport
Dépôt	https://github.com/devMehdi485/asrs-ml

Résumé

Ce rapport présente la conception et l'évaluation d'une chaîne de traitement automatique du langage naturel (NLP) destinée à exploiter 125 763 rapports d'incidents en texte libre de la base *Aviation Safety Reporting System* (ASRS). La démarche est guidée par les caractéristiques mesurées du corpus — texte rédigé librement, vocabulaire abrégé et hétérogène, déséquilibre marqué des catégories d'anomalies, apparition de risques nouveaux au fil du temps — et chaque décision méthodologique est présentée comme une réponse à une difficulté identifiée dans les données, puis évaluée par ses conséquences sur les résultats. La chaîne combine un prétraitement linguistique, une vectorisation (TF-IDF, word2vec, embeddings de phrases), une réduction de dimension (UMAP), un regroupement (comparaison K-Means / HDBSCAN), une modélisation de sujets (LDA) et une classification supervisée (régression logistique, SVM). Les principaux résultats quantitatifs sont : 81 thèmes (silhouette de 0,590 pour HDBSCAN contre 0,382 pour K-Means), un score F1 pondéré de 0,615 en classification, une cohérence c_v de 0,57 pour le modèle LDA, et l'isolement d'un ensemble de rapports atypiques correspondant à des risques émergents.

Mots-clés : traitement du langage naturel, sécurité aérienne, ASRS, regroupement de textes, modélisation de sujets, classification, détection d'anomalies.

Table des matières

1	Contexte et problématique	3
2	Objectifs	3
3	Démarche méthodologique	3
3.1	Propriétés du corpus et prétraitement	3
3.2	Représentation des récits	3
3.3	Réduction de dimension et regroupement	4
3.4	Modélisation des sujets, classification et détection d'anomalies	5
4	Résultats	5
4.1	Structure thématique	5
4.2	Évaluation du regroupement	5
4.3	Classification des anomalies	6
5	Analyse des tendances et des signaux faibles	7
6	Limites et perspectives	8
7	Conclusion	8

1 Contexte et problématique

La base *Aviation Safety Reporting System* (ASRS) regroupe des rapports d'incidents soumis volontairement par les acteurs du transport aérien. L'essentiel de l'information y est contenu dans un **champ de texte libre** décrivant l'événement. Le présent travail porte sur un export de 125 763 rapports (2002–2025) ; les champs textuels sont renseignés à 100 % et les métadonnées exploitées sont quasi complètes (type d'anomalie 99,7 %, phase de vol 95,9 %, type d'aéronef 98,9 %, date 100 %).

La difficulté centrale est que cette information n'est pas structurée et qu'un volume de cet ordre n'est pas traitable manuellement. Le problème d'ingénierie traité est donc le suivant : **concevoir une chaîne de traitement capable d'extraire automatiquement les causes récurrentes d'incidents, de classifier les types d'anomalies et de détecter les signaux faibles** (rapports atypiques potentiellement précurseurs), à partir du seul contenu textuel. Le **NLP (Natural Language Processing)**, ensemble de méthodes d'analyse automatique du langage écrit, fournit le cadre de cette chaîne.

2 Objectifs

1. Extraire automatiquement les thèmes d'incidents récurrents, sans nomenclature prédéfinie.
2. Prédire la catégorie d'anomalie d'un rapport à partir de son texte.
3. Détecter les rapports atypiques susceptibles de signaler des risques émergents.

3 Démarche méthodologique

La méthodologie n'est pas un catalogue d'algorithmes : chaque composant a été retenu en réponse à une difficulté observée dans le corpus ASRS. Cette section suit cette logique, en partant des propriétés mesurées des données pour en déduire les choix de traitement et leurs conséquences.

3.1 Propriétés du corpus et prétraitement

Trois propriétés du corpus déterminent l'ensemble des décisions ultérieures. D'abord, les récits sont rédigés librement : un même événement opérationnel est décrit avec des formulations très variables. Ensuite, l'anonymisation introduite par la NASA remplace noms et lieux par des marqueurs (**ZZZ**, **XXX**) qui, présents dans la quasi-totalité des rapports, constitueraient les jetons les plus fréquents du corpus s'ils étaient conservés. Enfin, le vocabulaire technique est fortement abrégé et orthographié de manière inconsistante (**rw** pour *runway*, **eng** pour *engine*).

La deuxième propriété impose un prétraitement avant toute statistique lexicale : retrait des marqueurs d'anonymisation et d'un ensemble de termes omniprésents et non discriminants (« aircraft », « flight »), puis lemmatisation pour regrouper les variantes flexionnelles (« engine », « engines »). Sans ce traitement, les regroupements refléteraient la présence de marqueurs plutôt que la nature des incidents. La validité de ce nettoyage est confirmée a posteriori par l'extraction de termes distinctifs par cluster (c-TF-IDF, § 3.3), qui restitue un vocabulaire spécifique aux incidents (par exemple « hydraulic, pump ») et non le vocabulaire générique du domaine.

3.2 Représentation des récits

La tâche de classification et la nomination des thèmes exigent une représentation dont on puisse lire les termes responsables d'une décision. Le **TF-IDF** (*Term Frequency – Inverse Document*

Frequency), qui pondère chaque mot par sa fréquence locale et l'inverse de sa fréquence dans le corpus, répond à ce besoin : il atténue le socle lexical commun (phraséologie, procédures) que partagent tous les rapports et fait ressortir les termes décisifs et peu fréquents qui caractérisent un incident particulier. Cette représentation sera réutilisée comme entrée des modèles de classification (§ 3.4), dont elle conditionne l'interprétabilité.

Le TF-IDF ne peut toutefois pas rapprocher deux écritures d'un même concept : **rw**y et **runway** y forment deux dimensions indépendantes. L'ampleur de cette limite a été quantifiée en entraînant un modèle **word2vec** (représentation vectorielle apprise par co-occurrence) sur le corpus : les plus proches voisins obtenus (**runway** → **rw**y à 0,84 ; **weather** → **thunderstorm** à 0,76 ; tableau 2) montrent que la synonymie de domaine est massive et qu'une représentation purement lexicale la manque.

Cette observation conduit, pour le regroupement, à représenter chaque rapport par un **embedding** (vecteur numérique encodant le sens global du texte) produit par un **Sentence Transformer** (modèle de phrases pré-entraîné, **all-MiniLM-L6-v2**). La raison est directement liée à la première propriété du corpus : deux rapports décrivant une même situation — par exemple une approche non stabilisée écrite « we were high and fast on final » ou « the approach became unstabilized and we went around » — ne partagent presque aucun mot et seraient jugés distants par TF-IDF, alors que leurs embeddings sont proches. La conséquence sur les résultats est mesurable : le regroupement opéré sur les embeddings atteint une silhouette de 0,590 (§ 3.3), nettement supérieure à ce que permettrait une représentation par mots-clés. Le TF-IDF est conservé en parallèle, non pour le regroupement, mais parce que son caractère interprétable reste nécessaire à la classification et à l'étiquetage.

3.3 Réduction de dimension et regroupement

Les embeddings comportent 384 dimensions pour 125 763 rapports. À cette dimensionnalité, les distances euclidiennes se concentrent et perdent leur pouvoir discriminant, ce qui dégrade les méthodes de regroupement par densité. Une réduction préalable est donc appliquée au moyen d'**UMAP** (*Uniform Manifold Approximation and Projection*), qui projette les vecteurs dans un espace de faible dimension en préservant les voisinages locaux ; ce dernier point écarte une réduction linéaire (ACP), qui ne conserverait pas la structure locale des groupes sémantiques. Cette réduction rend le regroupement par densité applicable et fournit la projection bidimensionnelle utilisée pour la visualisation.

Le nombre de types d'incidents n'est pas connu a priori, et l'examen du corpus révèle une distribution très inégale : quelques thèmes massifs (l'équipement représente 43,8 % des rapports, § 4) coexistent avec une longue traîne de thèmes rares, et une part substantielle des récits sont atypiques ou hors-sujet. Ces propriétés orientent le choix de l'algorithme. **K-Means** impose de fixer le nombre de groupes et attribue chaque rapport à un groupe, y compris les récits atypiques, ce qui dilue les thèmes. **HDBSCAN** (*Hierarchical Density-Based Spatial Clustering of Applications with Noise*) déduit le nombre de groupes de la densité, admet des groupes de tailles très différentes et étiquette comme « bruit » les points isolés. La comparaison des deux approches sur les mêmes données (tableau 1) départage : HDBSCAN obtient une silhouette de 0,590 et un indice de Davies-Bouldin de 0,575, contre 0,382 et 0,945 pour K-Means. HDBSCAN est donc retenu. Deux conséquences en découlent. D'une part, les 32 % de points classés « bruit » ne sont pas écartés mais réutilisés en entrée de la détection d'anomalies (§ 3.4), ce qui transforme une limite apparente du regroupement en ressource. D'autre part, la concordance entre les 81 thèmes obtenus et les catégories d'anomalies codées par les analystes est faible (pureté de 0,165) : ce résultat n'indique pas une erreur mais une différence de granularité, les thèmes issus du texte étant plus fins que la nomenclature officielle (un code « équipement » se subdivise en hydraulique, train, circuit d'huile, électrique, etc.).

L'étiquetage des thèmes pose un problème spécifique : les mots les plus fréquents d'un groupe sont le vocabulaire commun à tous les groupes et ne le caractérisent pas. Les termes distinctifs sont donc extraits par **c-TF-IDF**, variante du TF-IDF appliquée en traitant chaque groupe comme un document unique. Les 81 thèmes ainsi nommés ont ensuite été regroupés manuellement en 11 catégories métier afin d'offrir un niveau de lecture agrégé.

3.4 Modélisation des sujets, classification et détection d'anomalies

Un regroupement attribue chaque rapport à un thème unique, alors que les récits ASRS combinent fréquemment plusieurs problèmes (par exemple une déviation météorologique entraînant un écart d'altitude puis une difficulté de communication). Pour représenter cette multiplicité, une modélisation **LDA** (*Latent Dirichlet Allocation*), qui décrit chaque document comme un mélange de sujets, est ajoutée en complément ; la cohérence c_v de ses sujets atteint 0,57.

La classification vise à reconstituer la catégorie d'anomalie à partir du texte complet du rapport, dans une perspective de pré-tri automatique des nouveaux rapports. Les entrées étant des vecteurs TF-IDF creux et de grande dimension, des modèles linéaires sont adaptés à cette configuration : le **régression logistique** (estimation de probabilités d'appartenance) et le **SVM linéaire** (*Support Vector Machine*, séparation à marge maximale). Leur caractère auditable — la possibilité d'identifier les termes déterminant une prédiction — est un critère retenu dans un contexte de sécurité. Le champ d'anomalie étant en pratique multi-valué, il a été ramené à la catégorie principale (huit classes majoritaires) ; cette simplification borne la performance atteignable et explique en partie la difficulté sur les classes rares.

Enfin, les risques émergents ne disposent d'aucune étiquette et sont absents au début de la période étudiée ; ils ne peuvent donc être recherchés ni par apprentissage supervisé ni par mots-clés prédéfinis. La détection s'appuie en conséquence sur une méthode non supervisée, l'**Isolation Forest**, qui isole les points les plus éloignés de la masse dans l'espace des représentations, complétée par les points « bruit » d'HDBSCAN. Cette approche fait remonter des récits atypiques indépendamment de leur vocabulaire.

4 Résultats

4.1 Structure thématique

Le regroupement produit 81 thèmes, agrégés en 11 catégories (figure 1). La catégorie *Équipement & systèmes* concentre 43,8 % des rapports, devant *Sol & piste* (13,3 %) et *Trajectoire & altitude* (7,8 %). La prédominance de la première catégorie s'interprète comme une propension élevée des équipages à signaler les dysfonctionnements techniques plutôt que comme une fréquence de pannes ; elle indique un gisement de données pertinent pour une politique de maintenance fondée sur l'analyse des signalements.

Les termes distinctifs extraits par c-TF-IDF (figure 3) confèrent à chaque thème un contenu identifiable, condition nécessaire à l'exploitation opérationnelle des résultats.

4.2 Évaluation du regroupement

L'évaluation s'appuie sur trois indices internes : le **score de silhouette** (−1 à 1 ; une valeur élevée traduit des groupes compacts et séparés), l'**indice de Davies-Bouldin** (une valeur faible traduit une bonne séparation) et le **score de Calinski-Harabasz**. Les valeurs obtenues (tableau 1) établissent la supériorité d'HDBSCAN sur ce corpus.




FIGURE 1 – Répartition des rapports par catégorie (regroupement des 81 thèmes en 11 familles).




FIGURE 2 – Douze thèmes les plus volumineux.

La cohérence sémantique de la représentation est par ailleurs attestée par le modèle word2vec (tableau 2), dont les voisinages reproduisent des relations de domaine (abréviations, termes associés).

4.3 Classification des anomalies

Les performances sont mesurées par le score **F1** (moyenne harmonique de la précision et du rappel), rapporté en moyenne non pondérée (*macro*) et pondérée par les effectifs.

Le SVM linéaire atteint un F1 pondéré de 0,615. L'écart entre F1 macro (0,517) et F1 pondéré confirme l'effet du déséquilibre des classes : les catégories au vocabulaire spécifique sont bien reconnues (*ATC Issue*, F1 = 0,76 ; *NMAC*, 0,69 ; *Aircraft Equipment Problem Critical*, 0,67), tandis que les classes minoritaires et les rapports multi-anomalies abaissent la moyenne macro.




FIGURE 3 – Termes distinctifs (c-TF-IDF) des quatre principaux thèmes.

TABLE 1 – Indices internes de qualité du regroupement.

Algorithme	Groupes	Silhouette	Davies-Bouldin	Bruit	Pureté
K-Means	15	0,382	0,945	0 %	0,133
HDBSCAN	81	0,590	0,575	32 %	0,165

5 Analyse des tendances et des signaux faibles

L'horodatage des rapports permet de mesurer l'évolution de chaque thème (figures 4 et 5). Plusieurs thèmes présentent une progression significative sur la période récente. Les **incursions et erreurs au sol** augmentent, ce qui est cohérent avec la densification du trafic au sol et l'augmentation mécanique des situations de croisement sur les aires de manœuvre. Les **événements de fumée ou d'odeur en cabine** progressent également, de même que les rapports relatifs aux **marchandises dangereuses**, ce dernier point étant cohérent avec la croissance du fret.

La détection d'anomalies isole un ensemble de rapports atypiques dont l'examen fait apparaître des thématiques rares et récentes : rencontres avec des drones, brouillage du signal GPS, batteries au lithium. Ces thématiques étaient quasi absentes en début de période, ce qui illustre la capacité de l'approche à faire émerger des risques non anticipés. Le rapport suivant, classé parmi les plus atypiques, en est représentatif :

« Approach control advised there was unauthorized drone use in the area...I observed a drone pass just left of the aircraft, approximately 20 feet from our left wing. »

L'intérêt opérationnel de cette détection tient au fait que de tels rapports, minoritaires, ne seraient pas identifiés par une revue manuelle ni par une recherche par mots-clés portant sur des risques connus.

TABLE 2 – word2vec — plus proches voisins (similarité cosinus) sur le corpus.

Terme	Plus proches voisins
runway	rwyt (0,84), taxiway (0,65), intersecting (0,59), midfield (0,59)
engine	eng (0,69), feathered (0,57), magneto (0,54), crossbleed (0,54)
weather	thunderstorm (0,76), storm (0,74), bkn (0,68), forecast (0,66)
altitude	alt (0,70), descended (0,67), descend (0,65), level (0,64)

TABLE 3 – Classification de la catégorie d'anomalie (8 classes, entrées TF-IDF).

Modèle	F1 macro	F1 pondéré
Régression logistique	0,518	0,606
SVM linéaire	0,517	0,615

6 Limites et perspectives

L'interprétation des résultats est soumise à plusieurs réserves, toutes liées aux propriétés des données. Le déséquilibre des classes pénalise la reconnaissance des anomalies rares, comme l'indique l'écart entre F1 macro et F1 pondéré. L'anonymisation supprime un contexte potentiellement informatif (lieux, opérateurs). Le caractère volontaire de l'ASRS implique que le corpus reflète les incidents *signalés* et non l'ensemble des incidents, ce qui limite la portée statistique des fréquences observées. Enfin, le thème relatif à l'équipement reste hétérogène, conséquence du caractère généraliste du modèle d'embeddings utilisé.

Plusieurs prolongements répondraient directement à ces limites. L'emploi d'embeddings réentraînés sur un corpus aéronautique améliorerait la séparation des thèmes techniques. Une approche de modélisation de sujets fondée sur les embeddings (de type BERTopic) unifierait regroupement et nomination. Une formulation multi-étiquettes de la classification rendrait compte des rapports relevant de plusieurs anomalies. Le croisement des rapports atypiques avec des données externes (trafic, conditions météorologiques) permettrait enfin d'évaluer leur valeur prédictive.

7 Conclusion

Le travail décrit une chaîne de traitement complète permettant d'exploiter automatiquement 125 763 rapports d'incidents en texte libre. Les choix méthodologiques ont été déterminés par les propriétés mesurées du corpus et évalués par leurs effets sur les résultats : 81 thèmes interprétables (silhouette de 0,590), une classification atteignant un F1 pondéré de 0,615, une modélisation de sujets de cohérence $c_v = 0,57$, et l'isolement d'un ensemble de rapports atypiques correspondant à des risques émergents. L'ensemble structure une information jusque-là dispersée dans le texte et la rend exploitable pour l'analyse de la sécurité aérienne, ouvrant la voie aux prolongements identifiés ci-dessus.




FIGURE 4 – Volume mensuel de rapports (2002–2025).




FIGURE 5 – Répartition des principales anomalies par année.