


Analyse NLP des rapports d'incidents de sécurité aérienne

Extraction des causes récurrentes, classification des anomalies
et détection de signaux faibles sur la base **NASA ASRS**

Rapport technique — version pédagogique

TIDJANI Mehdi • FEUDJEU II LA GRACE • OUEDRAOGO
Martin

Projection UMAP des rapports (couleur = catégorie)



Projection sémantique des 125 763 rapports, colorée par catégorie d'incident

Jeu de données	NASA ASRS — 125 763 rapports (2002–2025)
Cadre	Projet A3 — équipe de 3 étudiants 3–4 semaines
Livrables	Pipeline NLP · Dashboards (Streamlit & React) · Rapport
Dépôt	https://github.com/devMehdi485/asrs-ml

Résumé

Le présent rapport documente un projet de **traitement automatique du langage naturel** appliqué à 125 763 rapports d'incidents de la base *Aviation Safety Reporting System* (ASRS) de la NASA. Son objectif est de transformer une grande quantité de récits écrits en texte libre en informations claires et exploitables pour la sécurité aérienne. La démarche enchaîne cinq grandes étapes : nettoyer les textes, les convertir en nombres, les regrouper par thème, identifier les sujets dominants, et enfin prédire le type d'incident. Chaque choix de méthode est justifié au regard des *caractéristiques propres au corpus ASRS* (texte libre, vocabulaire abrégé et hétérogène, classes déséquilibrées, risques émergents). Les résultats — 81 thèmes regroupés en 11 grandes familles, une classification atteignant un score F1 pondéré de 0,615, et la détection de risques émergents (drones, brouillage GPS, batteries au lithium) — sont systématiquement reliés aux enjeux opérationnels de la sécurité aérienne.

Mots-clés : traitement du langage, sécurité aérienne, ASRS, regroupement de textes, classification, détection d'anomalies.

Table des matières

1	Contexte et problématique	3
2	Objectifs	3
3	Méthodologie	3
3.1	Étape 1 — Nettoyage des récits	3
3.2	Étape 2 — Vectorisation : du texte aux nombres	4
3.3	Étape 3 — Regroupement des rapports par thème	5
3.4	Étape 4 — Modélisation des sujets (LDA)	5
3.5	Étape 5 — Prédire le type d'incident, et repérer l'inattendu	6
4	Résultats	6
4.1	Une cartographie en 81 thèmes et 11 familles	6
4.2	Quel algorithme de regroupement retenir ?	7
4.3	Vérifier que le modèle « comprend » le domaine	8
4.4	Prédire le type d'incident	8
5	Discussion : tendances et signaux faibles	9
6	Limites et perspectives	10
7	Conclusion	10

1 Contexte et problématique

La base *Aviation Safety Reporting System* (ASRS) rassemble des centaines de milliers de rapports d'incidents, soumis volontairement par les pilotes, contrôleurs et techniciens du transport aérien. Chaque rapport contient un **récit en texte libre** : une personne y raconte, avec ses propres mots, un événement qui a compromis ou failli compromettre la sécurité d'un vol.

Cette richesse est aussi la principale difficulté. L'information utile n'est pas rangée dans des cases : elle est noyée dans des paragraphes rédigés à la main, tous différents. Or un volume de 125 000 récits ne peut pas être lu, mémorisé et recoupé par un être humain.

La problématique du projet est donc la suivante : **comment exploiter automatiquement ces récits pour en extraire les causes récurrentes d'incidents, en classer les types, et repérer les signaux faibles susceptibles d'annoncer de futurs accidents ?** Pour y répondre, le projet s'appuie sur le **NLP (Natural Language Processing, ou traitement automatique du langage naturel)** : l'ensemble des techniques permettant à un ordinateur d'analyser et de « comprendre » du texte écrit en langage humain.

2 Objectifs

1. **Extraction des causes récurrentes** : faire émerger automatiquement, sans liste prédéfinie, les grands thèmes d'incidents présents dans les rapports.
2. **Classification des anomalies** : prédire la catégorie d'anomalie d'un rapport à partir de son texte.
3. **Détection de signaux faibles** : repérer les rapports atypiques décrivant des phénomènes rares et potentiellement précurseurs.

3 Méthodologie

Le corpus ASRS impose trois contraintes qui guident tous les choix techniques de ce projet, et qu'il faut garder en tête : **(i)** les récits sont rédigés librement, si bien qu'un même événement est décrit avec des mots très variés ; **(ii)** le vocabulaire est truffé d'abréviations et de jargon écrits de façon inconsistante (**rw**y pour *runway*, **eng** pour *engine*) ; **(iii)** les types d'incidents sont très déséquilibrés et certains risques sont *émergents*, donc absents au début de la période. La chaîne de traitement répond à ces contraintes en cinq temps : nettoyer, vectoriser, regrouper, modéliser les sujets, puis prédire.

3.1 Étape 1 — Nettoyage des récits

Problème ASRS. Pour protéger l'anonymat, la NASA remplace les noms propres et les lieux par des marqueurs comme **ZZZ** ou **XXX**. Ces marqueurs reviennent dans la quasi-totalité des récits : laissés tels quels, ils deviendraient *les jetons les plus fréquents du corpus*. S'y ajoute un vocabulaire de fond omniprésent (« aircraft », « flight », « pilot ») qui ne distingue aucun incident en particulier.

Pourquoi un traitement minimal serait insuffisant. Sans nettoyage, toute statistique de mots serait dominée par **ZZZ** et par ce jargon générique : les rapports seraient regroupés selon la présence de marqueurs d'anonymisation plutôt que selon la nature de l'incident. Le nettoyage (retrait des marqueurs, des mots vides et d'une liste de termes métier omniprésents, puis lemmatisation pour réunir « engine » et « engines ») élimine ce bruit. **Apport.** Il garantit que tout ce qui suit travaille sur le contenu réel des incidents.

Limite. Une lemmatisation et un filtrage trop agressifs peuvent gommer des nuances ou des codes techniques porteurs de sens ; le réglage de la liste de termes exclus reste empirique.

3.2 Étape 2 — Vectorisation : du texte aux nombres

Un algorithme ne traite que des nombres. Trois représentations, complémentaires, sont construites — chacune répond à un besoin différent du corpus ASRS.

TF-IDF — pour isoler les mots qui distinguent un incident. **TF-IDF** (Term Frequency – Inverse Document Frequency) pondère chaque mot d'autant plus fort qu'il est fréquent dans un rapport mais rare dans l'ensemble du corpus. **Problème ASRS.** Les récits partagent un socle lexical énorme (procédures, phraséologie ATC, « runway », « approach »...) ; ce qui distingue réellement un incident tient à quelques termes décisifs (« windshear », « hydraulic », « depressurization »). **Pourquoi un simple comptage de mots échouerait.** Un comptage brut donnerait autant de poids au socle commun qu'au terme discriminant ; TF-IDF écrase justement ce socle et fait ressortir le terme rare et informatif. **Apport.** Représentation *interprétable* : on peut lire les mots responsables d'une décision. Elle sert de base à la classification (étape 5) et à la nomination des thèmes (c-TF-IDF, ci-dessous).

Limite. TF-IDF ignore l'ordre des mots et la synonymie : `rwy` et `runway` restent deux colonnes distinctes, ce qui motive le recours aux embeddings.

Word2Vec — pour vérifier que le corpus « se tient » sémantiquement. **Word2Vec** apprend, à partir des co-occurrences, un vecteur par mot tel que les mots employés dans des contextes voisins se retrouvent proches. **Problème ASRS.** Le corpus est saturé d'abréviations écrites librement ; il faut s'assurer que `rwy` et `runway` renvoient bien au même concept. **Apport.** Entraîné sur le corpus lui-même, Word2Vec apprend la synonymie *propre au domaine* et confirme la cohérence des données (cf. tableau 2 : `runway`≈`rwy`, `weather`≈`thunderstorm`).

Limite. Word2Vec produit un vecteur *par mot* et ne représente pas le sens d'un récit entier ; il ne résout donc pas la comparaison de deux rapports.

Embeddings de phrases — pour rapprocher deux récits qui disent la même chose. Chaque rapport entier est transformé en un **vecteur numérique (embedding)** représentant son *sens global*, calculé par un **Sentence Transformer** (modèle de phrases pré-entraîné, ici `all-MiniLM-L6-v2`). **Problème ASRS.** Deux pilotes décrivent une même situation avec un vocabulaire très différent : une approche non stabilisée peut s'écrire « we were high and fast on final » ou « the approach became unstabilized and we went around ». **Pourquoi TF-IDF ou Word2Vec ne suffisent pas ici.** TF-IDF jugerait ces deux récits différents car ils ne partagent presque aucun mot ; moyenner des vecteurs Word2Vec diluerait le sens et perdrait la structure. L'embedding de phrase, lui, les place *proches* parce qu'il encode la situation décrite, pas les mots employés. **Apport.** C'est la représentation sur laquelle s'appuie le regroupement (étape 3), d'où des thèmes nettement plus cohérents.

Plutôt qu'une autre approche. TF-IDF est conservé pour sa *lisibilité* (nommer et classer), mais le regroupement s'appuie sur les embeddings de phrases car la variabilité de formulation est la norme dans des rapports rédigés librement — c'est précisément le cas que les seuls mots-clés gèrent mal.

Limite. Le modèle est pré-entraîné sur de l'anglais généraliste, pas aéronautique : certaines finesses du domaine sont estompées (ce qui motive des embeddings spécialisés en perspectives) ; de plus un embedding est moins directement interprétable qu'un vecteur TF-IDF.

3.3 Étape 3 — Regroupement des rapports par thème

UMAP — pour rendre le regroupement possible. UMAP (Uniform Manifold Approximation and Projection) est une technique de réduction de dimension qui compresse des vecteurs de grande taille en quelques dimensions tout en préservant les voisinages. **Problème ASRS.** Les embeddings ont des centaines de dimensions pour 125 763 rapports ; à cette échelle, les distances deviennent presque toutes équivalentes (« fléau de la dimension ») et le regroupement par densité échoue. **Pourquoi PCA serait insuffisant.** Une réduction linéaire comme l'ACP ne préserve pas la structure *locale* des groupes sémantiques ; UMAP, non linéaire, garde proches les rapports parlant du même incident. **Apport.** Elle rend HDBSCAN exploitable et fournit la carte 2-D.

Limite. La projection déforme les distances globales et ses coordonnées ne sont pas interprétables en soi.

K-Means vs HDBSCAN — découvrir des thèmes de tailles très inégales. **Problème ASRS.** On ignore *combien* de types d'incidents existent, et le corpus mêle quelques thèmes massifs (équipement) à une longue traîne de thèmes rares (drones, brouillage GPS), plus de nombreux récits atypiques. **K-Means** impose de fixer le nombre de groupes k à l'avance et *force chaque rapport* dans un groupe, y compris les récits hors-sujet — ce qui dilue les thèmes. **HDBSCAN (Hierarchical Density-Based Spatial Clustering of Applications with Noise)** découvre le nombre de groupes à partir de la densité, accepte des groupes de tailles et de formes très différentes, et *met de côté* les points isolés en les marquant comme « bruit ». **Apport.** HDBSCAN produit les 81 thèmes et, surtout, son « bruit » devient la matière première de la détection de signaux faibles (étape 5). La comparaison chiffrée (tableau 1) tranche : silhouette de 0,590 contre 0,382 pour K-Means.

Plutôt qu'une autre approche. HDBSCAN est retenu plutôt que K-Means car la structure des incidents ASRS — des amas thématiques denses et très inégaux, plus une masse de cas atypiques — correspond exactement à ce que le regroupement par densité gère bien, alors que K-Means suppose des groupes sphériques de tailles comparables et n'a pas de notion de « cas hors thème ».

Limite. HDBSCAN laisse 32% de bruit, produit un gros thème « équipement » hétérogène, et reste sensible au paramétrage (un garde-fou écarte les solutions dégénérées).

c-TF-IDF — pour nommer chaque thème. **Problème ASRS.** Une fois les thèmes formés, il faut les nommer ; or les mots les plus *fréquents* d'un thème sont le jargon commun (« aircraft », « runway »), identiques d'un thème à l'autre. **c-TF-IDF (class-based TF-IDF)** applique le principe du TF-IDF en traitant chaque thème comme un seul gros document, afin d'extraire les mots *distinctifs* de chaque groupe (« hydraulic, pump » pour l'un ; « drone, airspace » pour l'autre). **Apport.** Étiquetage automatique et lisible des 81 thèmes.

Limite. Purement lexical ; le regroupement des thèmes en 11 catégories métier a été fait manuellement par-dessus.

3.4 Étape 4 — Modélisation des sujets (LDA)

LDA (Latent Dirichlet Allocation) identifie automatiquement les principaux sujets d'un ensemble de textes, en représentant chaque document comme un *mélange* de sujets. **Problème ASRS.** Un même récit combine souvent plusieurs problèmes : une déviation pour cause météo qui entraîne un écart d'altitude puis un souci de communication ATC. **Pourquoi le clustering seul ne suffit pas.** Le regroupement assigne chaque rapport à *un seul* thème et masque donc ces mélanges. **Apport.** LDA offre une lecture transversale complémentaire, une mesure de cohérence

(c_v) et une exploration interactive via **pyLDAvis** (outil de visualisation des sujets et de leurs mots-clés).

Limite. LDA ignore l'ordre des mots et exige de fixer le nombre de sujets ; sur ce corpus, ses sujets sont moins nets que les groupes obtenus par embeddings ($c_v = 0,57$).

3.5 Étape 5 — Prédire le type d'incident, et repérer l'inattendu

Régression logistique & SVM — classer à partir du récit entier. Problème ASRS. Peut-on retrouver la catégorie d'anomalie codée par les analystes à partir du seul texte ? L'intérêt opérationnel est de *pré-trier automatiquement* les nouveaux rapports entrants. La prédiction se fait à partir du *contenu textuel global* du rapport (vectorisé), et non de mots isolés. **Pourquoi des règles à base de mots-clés échoueraient.** Les catégories partagent beaucoup de vocabulaire et le texte est bruité ; des règles manuelles ne passent pas à l'échelle de 8 classes sur 125 k récits. La **régression logistique (Logistic Regression)** estime la probabilité d'appartenance à chaque catégorie ; le **SVM (Support Vector Machine)** sépare les catégories en maximisant la marge entre elles. **Apport.** Un classifieur opérationnel (F1 pondéré de 0,615) qui alimente même une prédiction en direct dans le dashboard.

Plutôt qu'une autre approche. Des modèles linéaires sur TF-IDF sont préférés à un modèle profond car les représentations sont creuses et de grande dimension (cas idéal pour le linéaire), parce qu'ils restent *auditable* — on peut lire les mots décisifs, ce qui est essentiel en contexte de sécurité — et parce qu'un gain marginal de précision ne justifierait pas la perte de transparence.

Limite. Le champ d'anomalie est en réalité multi-étiquettes (un rapport relève souvent de plusieurs anomalies) ; il a été ramené à la classe principale, et le déséquilibre des classes pénalise les catégories rares.

Isolation Forest — détecter les signaux faibles. Isolation Forest (forêt d'isolement) est une méthode de détection d'anomalies qui considère qu'un point facile à « isoler » du reste des données est, justement, atypique. **Problème ASRS.** Les risques émergents (drones, brouillage GPS, batteries au lithium) n'ont pas d'étiquette et étaient quasi inexistantes au début de la période : on ne peut donc ni les lister à l'avance, ni les apprendre de façon supervisée. **Pourquoi une recherche par mots-clés échouerait.** On ne peut pas chercher les mots-clés d'un risque que l'on ne connaît pas encore. **Apport.** En travaillant sur les embeddings, l'Isolation Forest fait remonter les récits sémantiquement éloignés de la masse, quel que soit leur vocabulaire ; combinée au « bruit » d'HDBSCAN, elle révèle ces nouveaux risques.

Limite. « Atypique » ne veut pas dire « dangereux » : certains rapports remontés sont simplement mal rédigés ; une relecture humaine reste nécessaire et le taux de contamination est fixé empiriquement.

4 Résultats

4.1 Une cartographie en 81 thèmes et 11 familles

Le pipeline fait émerger 81 thèmes, regroupés en 11 catégories métier (figure 1). La catégorie **Équipement & systèmes** domine très nettement (43,8 % des rapports), devant les incidents **au sol et sur piste** (13,3 %) et les **écarts de trajectoire ou d'altitude** (7,8 %).

Cette prédominance ne signifie pas que les avions tombent sans cesse en panne : elle traduit surtout que les équipages **signalent massivement** le moindre problème technique. Pour un exploitant, c'est un argument fort en faveur d'une **maintenance proactive** : la matière existe pour anticiper les défaillances plutôt que de les subir.




FIGURE 1 – Répartition des incidents par catégorie (regroupement des 81 thèmes en 11 familles).




FIGURE 2 – Les douze thèmes d'incidents les plus volumineux.

Chaque thème reçoit un nom métier et des mots-clés caractéristiques (figure 3), ce qui rend la cartographie immédiatement lisible.

4.2 Quel algorithme de regroupement retenir ?

Trois mesures évaluent la qualité d'un regroupement : le **score de silhouette** (−1 à 1, proche de 1 = points bien regroupés) ; l'**indice de Davies-Bouldin** (plus faible = groupes mieux séparés) ; le **score de Calinski-Harabasz** (plus élevé = meilleurs groupes).

HDBSCAN est retenu : silhouette plus élevée et Davies-Bouldin plus faible. La faible correspondance avec les catégories officielles (« pureté ») est normale : les thèmes obtenus sont plus fins que la dizaine de catégories codées par les analystes. Les 32 % de points « bruit » alimentent la détection de signaux faibles.




FIGURE 3 — Nuages de mots (c-TF-IDF) des quatre principaux thèmes.

TABLE 1 — Comparaison des deux algorithmes de regroupement.

Modèle	Clusters	Silhouette	Davies-Bouldin	Bruit	Pureté
K-Means	15	0,382	0,945	0 %	0,133
HDBSCAN (retenu)	81	0,590	0,575	32 %	0,165

4.3 Vérifier que le modèle « comprend » le domaine

Word2Vec apprend, sans aide, des associations pertinentes (tableau 2). La qualité des sujets LDA, mesurée par la **cohérence** c_v (un score indiquant si les mots d'un sujet vont bien ensemble), atteint 0,57.

TABLE 2 — Word2Vec — mots les plus proches (similarité cosinus) appris sur le corpus.

Terme	Voisins les plus proches
runway	rwy (0,84), taxiway (0,65), intersecting (0,59), midfield (0,59)
engine	eng (0,69), feathered (0,57), magneto (0,54), crossbleed (0,54)
weather	thunderstorm (0,76), storm (0,74), bkn (0,68), forecast (0,66)
altitude	alt (0,70), descended (0,67), descend (0,65), level (0,64)

4.4 Prédire le type d'incident

Le score **F1** (entre 0 et 1) combine précision et rappel; on distingue le *F1 macro* (moyenne simple) et le *F1 pondéré* (tenant compte de la taille des classes).

Les catégories au vocabulaire net sont les mieux reconnues (*ATC Issue*, $F1=0,76$; *NMAC*, 0,69), tandis que les catégories rares restent plus difficiles.

TABLE 3 – Performance de la classification (8 catégories d'anomalies, TF-IDF).

Modèle	F1 macro	F1 pondéré
Régression logistique	0,518	0,606
SVM linéaire	0,517	0,615

5 Discussion : tendances et signaux faibles

Les résultats précédents donnent une photographie ; l’analyse temporelle donne le film. En suivant l’évolution des thèmes (figures 4 et 5), plusieurs tendances ressortent, dont l’interprétation a un intérêt opérationnel direct :

- **Incursions et erreurs au sol** — **en hausse**, cohérent avec la **densification du trafic** : plus d’avions au sol, plus de croisements, plus d’occasions d’erreur sur les voies de circulation.
- **Fumées et odeurs en cabine** — **en hausse**, appelant une vigilance accrue sur la qualité de l’air et les circuits de prélèvement.
- **Marchandises dangereuses** — **en hausse**, cohérent avec la croissance du fret.




FIGURE 4 – Volume mensuel de rapports (2002–2025).




FIGURE 5 – Heatmap (carte de chaleur) : type d’anomalie × année.

L’apport le plus important concerne les **signaux faibles** : la détection d’anomalies fait remonter des phénomènes rares mais lourds de sens (drones, brouillage GPS, batteries au lithium), quasi inexistants il y a quinze ans. Un récit l’illustre :

« *Approach control advised there was unauthorized drone use in the area...I observed a drone pass just left of the aircraft, approximately 20 feet from our left wing.* »

Un analyste humain, face à 125 000 rapports, passerait à côté. Le système le fait remonter en tête de liste : c'est la valeur d'un détecteur de signaux faibles — voir tôt ce qui pourrait devenir, demain, une nouvelle catégorie d'accidents.

6 Limites et perspectives

Plusieurs limites encadrent l'interprétation : le **déséquilibre des classes** (qui pénalise les catégories rares), les **données anonymisées** (perte de contexte), et le **biais de déclaration** (le corpus reflète les incidents *signalés*, non l'ensemble des incidents). Plusieurs pistes prolongeraient le travail : **BERTopic** (découverte de thèmes combinant embeddings et regroupement, avec suivi temporel intégré), des **embeddings spécialisés** ré-entraînés sur un corpus aéronautique (pour mieux séparer le thème « équipement »), une **classification multi-étiquettes** (plusieurs anomalies par rapport), et le croisement des signaux faibles avec des données externes (trafic, météo) en vue d'une analyse prédictive.

7 Conclusion

Le projet part d'une matière brute — 125 763 récits illisibles à l'échelle humaine — et la transforme en information structurée : 81 thèmes interprétables regroupés en 11 familles, un modèle de classification opérationnel (F1 pondéré de 0,615), un dispositif de détection de signaux faibles, et deux tableaux de bord interactifs. Au-delà des chiffres, la valeur du travail tient à cette **transformation de récits bruts en intelligence exploitable** : en rendant visibles les causes récurrentes, les tendances et les risques émergents, l'approche fournit un véritable outil d'aide à la décision pour la sécurité aérienne.