


Analyse NLP des rapports d'incidents de sécurité aérienne

Extraction des causes récurrentes, classification des anomalies
et détection de signaux faibles sur la base **NASA ASRS**

Rapport technique — version pédagogique

Mehdi Tidjani • [Étudiant 2] • [Étudiant 3]

Projection UMAP des rapports (couleur = catégorie)



Projection sémantique des 125 763 rapports, colorée par catégorie d'incident

Jeu de données	NASA ASRS — 125 763 rapports (2002–2025)
Cadre	Projet A3 — équipe de 3 étudiants 3–4 semaines
Livrables	Pipeline NLP · Dashboards (Streamlit & React) · Rapport
Dépôt	https://github.com/devMehdi485/asrs-ml

Résumé

Le présent rapport documente un projet de **traitement automatique du langage naturel** appliqué à 125 763 rapports d'incidents de la base *Aviation Safety Reporting System* (ASRS) de la NASA. Son objectif est de transformer une grande quantité de récits écrits en texte libre en informations claires et exploitables pour la sécurité aérienne. La démarche enchaîne cinq grandes étapes : nettoyer les textes, les convertir en nombres, les regrouper par thème, identifier les sujets dominants, et enfin prédire le type d'incident. Le document est volontairement rédigé de façon pédagogique : chaque terme technique est expliqué lors de sa première apparition, et chaque choix de méthode est justifié. Les résultats — 81 thèmes regroupés en 11 grandes familles, une classification atteignant un score F1 pondéré de 0,615, et la détection de risques émergents (drones, brouillage GPS, batteries au lithium) — sont systématiquement reliés aux enjeux opérationnels de la sécurité aérienne.

Mots-clés : traitement du langage, sécurité aérienne, ASRS, regroupement de textes, classification, détection d'anomalies.

Table des matières

1	Contexte et problématique	3
2	Objectifs	3
3	Méthodologie : une chaîne de traitement en cinq temps	3
3.1	Étape 1 — Préparer les données et nettoyer les textes	3
3.2	Étape 2 — Transformer le texte en nombres (vectorisation)	4
3.3	Étape 3 — Regrouper les rapports par thème (clustering)	4
3.4	Étape 4 — Identifier les sujets dominants (LDA)	5
3.5	Étape 5 — Prédire le type d'incident (classification)	5
4	Résultats	5
4.1	Une cartographie en 81 thèmes et 11 familles	5
4.2	Quel algorithme de regroupement retenir ?	6
4.3	Vérifier que le modèle « comprend » le domaine	7
4.4	Prédire le type d'incident	7
5	Discussion : tendances et signaux faibles	8
6	Limites et perspectives	9
7	Conclusion	9

1 Contexte et problématique

La base *Aviation Safety Reporting System* (ASRS) rassemble des centaines de milliers de rapports d'incidents, soumis volontairement par les pilotes, contrôleurs et techniciens du transport aérien. Chaque rapport contient un **récit en texte libre** : une personne y raconte, avec ses propres mots, un événement qui a compromis ou failli compromettre la sécurité d'un vol.

Cette richesse est aussi la principale difficulté. L'information utile n'est pas rangée dans des cases : elle est noyée dans des paragraphes rédigés à la main, tous différents. Or un volume de 125 000 récits ne peut pas être lu, mémorisé et recoupé par un être humain.

La problématique du projet est donc la suivante : **comment exploiter automatiquement ces récits pour en extraire les causes récurrentes d'incidents, en classer les types, et repérer les signaux faibles susceptibles d'annoncer de futurs accidents ?** Pour répondre à cette question, le projet s'appuie sur le **NLP (Natural Language Processing, ou traitement automatique du langage naturel)** : il s'agit de l'ensemble des techniques permettant à un ordinateur d'analyser et de « comprendre » du texte écrit en langage humain. C'est cette discipline qui va permettre de structurer, regrouper et hiérarchiser automatiquement le contenu des rapports.

2 Objectifs

1. **Extraction des causes récurrentes** : faire émerger automatiquement, sans liste prédéfinie, les grands thèmes d'incidents présents dans les rapports.
2. **Classification des anomalies** : prédire la catégorie d'anomalie d'un rapport à partir de son texte.
3. **Détection de signaux faibles** : repérer les rapports atypiques décrivant des phénomènes rares et potentiellement précurseurs.

3 Méthodologie : une chaîne de traitement en cinq temps

La méthode suit un enchaînement logique, où chaque étape prépare la suivante : on commence par *nettoyer* le texte, puis on le *transforme en nombres*, ce qui permet ensuite de *regrouper* les rapports, d'en *extraire les sujets*, et enfin de *prédire* le type d'incident. Cette section décrit chaque étape et justifie le choix retenu.

3.1 Étape 1 — Préparer les données et nettoyer les textes

L'étude porte sur 125 763 rapports (2002–2025). Les récits sont disponibles pour tous les rapports, et les informations clés sont presque toujours renseignées (type d'anomalie 99,7 %, phase de vol 95,9 %, type d'aéronef 98,9 %, date 100 %). Les données proviennent de l'outil officiel de la NASA ; un jeu équivalent est aussi diffusé sur **Kaggle** (une plateforme publique de jeux de données et de notebooks), utilisé ici comme source complémentaire pour la reproductibilité et la comparaison avec d'autres travaux.

Les textes subissent ensuite un **nettoyage** : on enlève les marqueurs d'anonymisation, on met tout en minuscules, on découpe les phrases en mots, on retire les mots très courants sans valeur informative, et on ramène chaque mot à sa forme de base.

Pourquoi ce choix pour le projet ? Le nettoyage sert simplement à réduire le « bruit » — c'est-à-dire tout ce qui parasite l'analyse — pour que les méthodes suivantes se concentrent sur les mots réellement porteurs de sens.

3.2 Étape 2 — Transformer le texte en nombres (vectorisation)

Un ordinateur ne manipule pas des mots mais des nombres. Il faut donc convertir chaque rapport en une suite de nombres : c'est la **vectorisation**. Trois représentations complémentaires sont utilisées.

TF-IDF (**Term Frequency – Inverse Document Frequency**, soit « fréquence du terme – fréquence inverse de document ») est une méthode qui attribue à chaque mot un poids d'autant plus élevé qu'il est fréquent dans un rapport mais rare dans l'ensemble du corpus. Un mot banal partout obtient un poids faible ; un mot spécifique obtient un poids fort.

Pourquoi ce choix pour le projet ? TF-IDF est simple, rapide et surtout *interprétable* : on peut lire directement quels mots caractérisent un thème. Elle sert de base à la classification et à la description des groupes.

Word2Vec est une méthode qui apprend, pour chaque mot, un vecteur numérique tel que les mots de sens proche se retrouvent proches dans l'espace. Entraînée sur le corpus, elle « apprend » le vocabulaire du domaine aéronautique.

Pourquoi ce choix pour le projet ? Word2Vec permet de vérifier que les données et le nettoyage sont cohérents : si le modèle place correctement les mots proches, c'est que le signal sémantique est bien présent.

Enfin, chaque rapport entier est transformé en un **vecteur numérique appelé *embedding***, qui représente le *sens global* du texte (et pas seulement des mots isolés). Deux récits décrivant la même situation avec des mots différents auront des embeddings proches. Ces embeddings sont produits par un **Sentence Transformer** (modèle de phrases, ici **all-MiniLM-L6-v2**) : un réseau de neurones pré-entraîné qui encode une phrase complète en un seul vecteur.

Pourquoi ce choix pour le projet ? Les embeddings de phrases captent le sens d'un récit même quand le vocabulaire varie d'un pilote à l'autre ; ils donnent donc des regroupements bien plus cohérents que les seuls mots.

3.3 Étape 3 — Regrouper les rapports par thème (clustering)

Le **clustering** (ou regroupement automatique) consiste à rassembler les rapports qui se ressemblent, sans étiquette préalable. Avant de regrouper, les embeddings (qui comportent des centaines de dimensions) sont compressés grâce à **UMAP (Uniform Manifold Approximation and Projection)**, une technique de *réduction de dimension* : elle projette les vecteurs dans un espace beaucoup plus petit tout en préservant les proximités entre points.

Pourquoi ce choix pour le projet ? UMAP réduit le bruit, accélère les calculs et rend la visualisation possible en 2 dimensions.

Deux algorithmes de regroupement sont *comparés* sur les mêmes données :

- **K-Means** découpe les données en un nombre k de groupes fixé à l'avance, en rapprochant chaque point du centre de son groupe.
- **HDBSCAN (Hierarchical Density-Based Spatial Clustering of Applications with Noise)** regroupe les points selon leur *densité* : il découvre tout seul le nombre de groupes et met de côté les points isolés en les marquant comme « bruit ».

Pourquoi ce choix pour le projet ? Comparer deux familles d'algorithmes (par partition et par densité) permet de choisir objectivement le meilleur sur la base de mesures chiffrées, plutôt que d'en imposer un arbitrairement. De plus, le « bruit » détecté par HDBSCAN servira ensuite à repérer les signaux faibles.

Le clustering produit des **thèmes** fins. Pour offrir une vue d'ensemble lisible, ces thèmes sont ensuite **regroupés à la main en 11 catégories métier** (grandes familles). Il faut donc distinguer deux niveaux :

- les **thèmes d'incidents** : les 81 groupes fins issus automatiquement du clustering (p. ex. « Problèmes de train d'atterrissage ») ;
- les **catégories d'incidents** : 11 macro-familles regroupant ces thèmes selon une nomenclature métier proche de celle des analystes (p. ex. « Équipement & systèmes »).

Pour nommer chaque thème, on utilise le **c-TF-IDF (class-based TF-IDF)** : c'est le principe du TF-IDF, mais appliqué à chaque cluster pris comme un seul gros document, afin d'en extraire les mots les plus caractéristiques.

3.4 Étape 4 — Identifier les sujets dominants (LDA)

En complément du clustering, une modélisation **LDA (Latent Dirichlet Allocation)** est réalisée. Il s'agit d'une méthode qui identifie automatiquement les principaux *sujets* abordés dans un ensemble de textes, un même rapport pouvant relever de plusieurs sujets à la fois.

Pourquoi ce choix pour le projet ? LDA et clustering se complètent : le clustering range chaque rapport dans un seul groupe, tandis que LDA révèle les sujets transversaux qui traversent plusieurs rapports. Cela enrichit l'interprétation des thèmes.

La visualisation interactive de ces sujets est produite avec **pyLDavis**, un outil qui affiche les sujets et leurs mots-clés de façon explorable.

3.5 Étape 5 — Prédire le type d'incident (classification)

La dernière étape est *supervisée* : à partir d'exemples étiquetés, un modèle apprend à **prédire la catégorie d'anomalie d'un rapport à partir de son texte complet** (et non de mots isolés : c'est l'ensemble du récit, vectorisé, qui décide). Deux modèles sont employés :

- la **régression logistique (Logistic Regression)**, qui estime la probabilité qu'un rapport appartienne à chaque catégorie ;
- le **SVM (Support Vector Machine, machine à vecteurs de support)**, qui sépare les catégories en traçant la frontière qui laisse la plus grande marge entre elles.

Pourquoi ce choix pour le projet ? Ces deux modèles sont rapides, robustes et *interprétables* (on peut voir quels mots font pencher la décision) : des qualités plus utiles ici qu'un gain de précision apporté par un modèle opaque.

Enfin, pour repérer les rapports atypiques, on utilise un **Isolation Forest (forêt d'isolement)** : une méthode de détection d'anomalies qui considère qu'un point facile à « isoler » du reste des données est, justement, anormal.

Pourquoi ce choix pour le projet ? C'est exactement ce que l'on cherche pour les signaux faibles : faire remonter les récits qui sortent du lot.

4 Résultats

4.1 Une cartographie en 81 thèmes et 11 familles

Le pipeline fait émerger 81 thèmes, regroupés en 11 catégories métier (figure 1). La catégorie **Équipement & systèmes** domine très nettement (43,8 % des rapports), devant les incidents **au sol et sur piste** (13,3 %) et les **écarts de trajectoire ou d'altitude** (7,8 %).




FIGURE 1 – Répartition des incidents par catégorie (regroupement des 81 thèmes en 11 familles).

Cette prédominance ne signifie pas que les avions tombent sans cesse en panne : elle traduit surtout que les équipages **signalent massivement** le moindre problème technique. Pour un exploitant, c'est un argument fort en faveur d'une **maintenance proactive** : la matière existe pour anticiper les défaillances plutôt que de les subir.




FIGURE 2 – Les douze thèmes d'incidents les plus volumineux.

Chaque thème reçoit un nom métier et des mots-clés caractéristiques (figure 3), ce qui rend la cartographie immédiatement lisible.

4.2 Quel algorithme de regroupement retenir ?

Pour comparer K-Means et HDBSCAN, on utilise trois mesures de qualité d'un regroupement :

- le **score de silhouette (Silhouette Score)**, compris entre -1 et 1 : plus il est proche de 1 , mieux les points sont regroupés ;
- l'**indice de Davies-Bouldin (Davies-Bouldin Index)** : plus il est *faible*, mieux les groupes sont séparés ;




FIGURE 3 – Nuages de mots (c-TF-IDF) des quatre principaux thèmes.

- le **score de Calinski-Harabasz (Calinski-Harabasz Score)** : rapport entre la dispersion entre groupes et à l'intérieur des groupes ; plus il est élevé, mieux c'est.

TABLE 1 – Comparaison des deux algorithmes de regroupement.

Modèle	Clusters	Silhouette	Davies-Bouldin	Bruit	Pureté
K-Means	15	0,382	0,945	0 %	0,133
HDBSCAN (retenu)	81	0,590	0,575	32 %	0,165

HDBSCAN est retenu : sa silhouette est plus élevée (0,590 contre 0,382) et son indice de Davies-Bouldin plus faible, signe de groupes mieux séparés. La faible correspondance avec les catégories officielles d'anomalies (mesurée par la « pureté ») est normale : les thèmes obtenus sont plus fins que la dizaine de catégories codées par les analystes. Les 32 % de points classés « bruit » ne sont pas jetés : ils alimentent la détection de signaux faibles.

4.3 Vérifier que le modèle « comprend » le domaine

Le modèle Word2Vec apprend, sans aide, des associations pertinentes (tableau 2) : par exemple **runway** (piste) est proche de **rwy** (son abréviation) et de **taxiway** (voie de circulation). Cela confirme la qualité des données. De son côté, la qualité des sujets LDA se mesure par la **cohérence** c_v (un score indiquant si les mots d'un sujet vont bien ensemble) : elle atteint 0,57, ce qui correspond à des sujets lexicalement homogènes.

4.4 Prédire le type d'incident

Le score utilisé est le **F1** : une note entre 0 et 1 qui combine la précision et le rappel (1 = parfait). On distingue le *F1 macro* (moyenne simple sur toutes les catégories) et le *F1 pondéré* (qui tient compte de la taille des catégories).

Avec un F1 pondéré de 0,615 sur 8 catégories et du texte entièrement libre, le résultat est

TABLE 2 – Word2Vec — mots les plus proches (similarité cosinus) appris sur le corpus.

Terme	Voisins les plus proches
runway	rwy (0,84), taxiway (0,65), intersecting (0,59), midfield (0,59)
engine	eng (0,69), feathered (0,57), magneto (0,54), crossbleed (0,54)
weather	thunderstorm (0,76), storm (0,74), bkn (0,68), forecast (0,66)
altitude	alt (0,70), descended (0,67), descend (0,65), level (0,64)

TABLE 3 – Performance de la classification (8 catégories d'anomalies, TF-IDF).

Modèle	F1 macro	F1 pondéré
Régression logistique	0,518	0,606
SVM linéaire	0,517	0,615

satisfaisant. Les catégories au vocabulaire net sont les mieux reconnues (*ATC Issue*, $F1 = 0,76$; *NMAC*, 0,69), tandis que les catégories rares restent plus difficiles.

5 Discussion : tendances et signaux faibles

Les résultats précédents donnent une photographie ; l'analyse temporelle, elle, donne le film. En suivant l'évolution des thèmes dans le temps (figures 4 et 5), plusieurs tendances ressortent, dont l'interprétation a un intérêt opérationnel direct :

- **Incursions et erreurs au sol — en hausse.** Cette progression est cohérente avec la **densification du trafic** : plus d'avions au sol, plus de croisements, donc plus d'occasions d'erreur sur les voies de circulation.
- **Fumées et odeurs en cabine — en hausse.** Sujet sensible, qui appelle une vigilance accrue sur la qualité de l'air et les circuits de prélèvement.
- **Marchandises dangereuses — en hausse.** Cohérent avec la croissance du fret, avec des enjeux de conformité documentaire et de sûreté.




FIGURE 4 – Volume mensuel de rapports (2002–2025).

L'apport le plus important concerne les **signaux faibles**. La détection d'anomalies fait remonter des phénomènes rares mais lourds de sens : les rencontres avec des **drones**, le **brouillage du signal GPS** et les **batteries au lithium** — des sujets quasi inexistant il y a quinze ans. Un récit l'illustre :

« Approach control advised there was unauthorized drone use in the area...I observed a drone pass just left of the aircraft, approximately 20 feet from our left wing. »




FIGURE 5 — Heatmap (carte de chaleur) : type d'anomalie × année.

Un analyste humain, face à 125 000 rapports, passerait à côté. Le système, lui, le fait remonter en tête de liste. C'est précisément la valeur d'un détecteur de signaux faibles : voir tôt ce qui pourrait devenir, demain, une nouvelle catégorie d'accidents.

6 Limites et perspectives

Plusieurs limites encadrent l'interprétation des résultats :

- **Déséquilibre des classes** : certaines catégories sont bien plus fréquentes que d'autres, ce qui pénalise la reconnaissance des catégories rares.
- **Données anonymisées** : la suppression des lieux et identifiants fait perdre un contexte parfois utile.
- **Biais de déclaration** : l'ASRS étant volontaire, le corpus reflète les incidents *signalés*, et non l'ensemble des incidents survenus.

Plusieurs pistes permettraient d'aller plus loin. **BERTopic** — une méthode récente de découverte de thèmes combinant embeddings et regroupement, avec suivi temporel intégré — offrirait une thématisation de bout en bout. Des **embeddings spécialisés**, ré-entraînés sur un corpus aéronautique, sépareraient mieux les thèmes techniques. Une **classification multi-étiquettes** (plusieurs anomalies par rapport) refléterait mieux la réalité. Enfin, croiser les signaux faibles avec des données externes (trafic, météo) ouvrirait la voie à une analyse prédictive.

7 Conclusion

Le projet part d'une matière brute — 125 763 récits illisibles à l'échelle humaine — et la transforme en information structurée : 81 thèmes interprétables regroupés en 11 familles, un modèle de classification opérationnel (F1 pondéré de 0,615), un dispositif de détection de signaux faibles, et deux tableaux de bord interactifs accessibles même à un public non spécialiste.

Au-delà des chiffres, la valeur du travail tient à cette **transformation de récits bruts en intelligence exploitable**. En rendant visibles les causes récurrentes, les tendances et les risques émergents, l'approche fournit un véritable outil d'aide à la décision pour la sécurité aérienne — et montre, plus largement, comment le traitement automatique du langage peut valoriser les grandes bases de retour d'expérience.

Sources des données : NASA Aviation Safety Reporting System (<https://asrs.arc.nasa.gov/>) et jeu équivalent sur Kaggle. Code, dashboards et reproductibilité : <https://github.com/devMehdi485/asrs-ml>.